



Université Sorbonne Paris Nord

Institut Galilée

Master 1 – Mathématiques appliquées aux données

Analyse en Composantes Principales (ACP)

Projet semestriel 2

Étudiante :

Mlle FAYE Marie Pierre Gnillane Ndew

Encadreur :

Mme Thanh Mai Pham Ngoc

Année universitaire :

2025 – 2026

Professeur principal :

Mr BOYER Pascal

Table des matières

Introduction	3
1 Cadre mathématique et notations	4
1.1 Le tableau de données	4
1.2 Distance euclidienne	4
1.3 Prétraitement : centrage et réduction	5
1.4 Les deux types d'ACP	5
2 Inertie et distances	6
2.1 Distance euclidienne entre deux individus	6
2.2 Inertie du nuage des individus	6
2.3 Métrique sur $\mathbb{R}^n$ et nuage des variables	7
3 Analyse du nuage des individus	9
3.1 Diagonalisation de R et vecteurs propres	9
3.2 Problème d'optimisation	9
3.3 Solution et composantes principales	10
4 Analyse du nuage des variables	12
4.1 Le nuage des variables et la projection sur un axe	12
4.2 Problème d'optimisation : maximiser les $\cos^2$	12
4.3 Solution : vecteurs propres de $\frac{1}{n}ZZ^\top$	13
4.4 Position des variables dans le plan factoriel	14
5 Formules de passage et SVD	15
5.1 Lien entre les deux nuages	15
5.2 Les loadings sont des corrélations	16
5.3 Décomposition en Valeurs Singulières (SVD)	16
6 Interprétation des résultats	18
6.1 Qualité de la réduction de dimension	18
6.2 Qualité de représentation des individus	18
6.3 Qualité de représentation des variables – Cercle des corrélations	19
7 Choix du nombre de composantes à retenir	20
8 Applications numériques	22
8.1 Premier exemple : le jeu de données Iris	22
8.1.1 Présentation des données	22
8.1.2 Mise en œuvre sous R	22
8.1.3 Analyse des valeurs propres	22
8.1.4 Cercle des corrélations	23
8.1.5 Plan des individus	24
8.2 Deuxième exemple : le jeu de données Decathlon	25
8.2.1 Présentation des données	25
8.2.2 Mise en œuvre sous R	25
8.2.3 Analyse des valeurs propres	25
8.2.4 Cercle des corrélations	26

8.2.5	Plan des individus	27
8.3	Comparaison des deux applications	29
Conclusion		30
Références bibliographiques		31

Introduction

Dans de nombreux domaines scientifiques, les données collectées impliquent un grand nombre de variables mesurées simultanément sur les mêmes individus. Lorsque p est grand, l'analyse directe de ces données devient difficile : les variables sont souvent corrélées entre elles, ce qui introduit une redondance d'information, et la visualisation dans un espace de grande dimension est impossible. La **réduction de dimension** répond à ce besoin : il s'agit de construire un petit nombre de nouvelles variables synthétiques qui résument l'essentiel de l'information contenue dans les données originelles, tout en minimisant la perte d'information.

L'**Analyse en Composantes Principales (ACP)** est la méthode de réduction de dimension linéaire la plus répandue. Elle fut introduite par Karl PEARSON en 1901 dans un cadre géométrique, puis formalisée de manière algébrique par Harold HOTELLING en 1933, qui donna à la méthode sa forme moderne fondée sur la diagonalisation d'une matrice de covariance ou de corrélation. Depuis lors, l'ACP est devenue un outil incontournable en statistique multivariée, en apprentissage automatique et en analyse exploratoire des données.

D'un point de vue mathématique, l'ACP poursuit trois objectifs simultanés. Le premier est la **décorrélation** : les composantes principales sont construites de façon à être deux à deux non corrélées, éliminant ainsi la redondance entre variables. Le deuxième est la **maximisation de la variance** : chaque composante principale capture la direction de l'espace de départ qui concentre le plus de variabilité résiduelle, garantissant que l'information perdue lors de la projection est minimale. Le troisième est la **dualité individus-variables** : l'ACP analyse simultanément le nuage des n individus dans $\mathbb{R}^p$ et le nuage des p variables dans $\mathbb{R}^n$, les deux analyses étant reliées par les mêmes valeurs propres et les formules de passage.

Ce rapport présente le cadre mathématique complet de l'ACP dans sa version **normée**, c'est-à-dire appliquée aux données centrées-réduites. Le plan est le suivant. La section 1 pose les notations et le prétraitement des données. La section 2 introduit la notion d'inertie et la distance euclidienne entre individus, avec une démonstration complète du fait que l'inertie totale vaut p . Les sections 3 et 4 traitent respectivement l'analyse du nuage des individus et celle du nuage des variables : on y démontre les propriétés fondamentales des composantes principales ainsi que le rôle du cercle des corrélations. La section 5 établit les formules de passage entre les deux nuages et introduit la décomposition en valeurs singulières. Les sections 6 et 7 sont consacrées à l'interprétation des résultats et aux critères de choix du nombre de composantes. La section 8 présente une application numérique de l'ACP.

1. Cadre mathématique et notations

1.1. Le tableau de données

On considère un tableau de données numériques où n individus sont décrits sur p variables quantitatives.

Matrice des données. On note $X = (x_{ij})_{n \times p}$ la matrice des données brutes, où $x_{ij} \in \mathbb{R}$ désigne la valeur du i -ème individu sur la j -ème variable. On lui associe :

- le **vecteur-individu** $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top \in \mathbb{R}^p$ (ligne i de X),
- le **vecteur-variable** $\mathbf{x}^j = (x_{1j}, \dots, x_{nj})^\top \in \mathbb{R}^n$ (colonne j de X).

Cette structure donne naissance à deux nuages de points que l'ACP analyse simultanément :

- le **nuage des individus** : n points dans $\mathbb{R}^p$,
- le **nuage des variables** : p points dans $\mathbb{R}^n$.

1.2. Distance euclidienne

Avant d'introduire le prétraitement des données, il est nécessaire de préciser comment on mesure la proximité entre deux individus, notion qui sera centrale dans toute l'analyse.

Définition – Distance euclidienne

Soient deux individus i et i' représentés par leurs vecteurs $\mathbf{x}_i, \mathbf{x}_{i'} \in \mathbb{R}^p$. La **distance euclidienne** entre ces deux individus est définie par :

$$d(\mathbf{x}_i, \mathbf{x}_{i'}) = \sqrt{\sum_{j=1}^p (x_{ij} - x_{i'j})^2},$$

ou de manière équivalente, en travaillant sur le carré de la distance :

$$d^2(\mathbf{x}_i, \mathbf{x}_{i'}) = \sum_{j=1}^p (x_{ij} - x_{i'j})^2 = \|\mathbf{x}_i - \mathbf{x}_{i'}\|^2.$$

C'est la longueur du segment reliant les deux points dans $\mathbb{R}^p$: elle additionne les écarts au carré sur chacune des p coordonnées.

Une difficulté pratique apparaît lorsque les variables sont exprimées sur des échelles différentes : une variable en grammes et une variable en centimètres n'ont pas le même ordre de grandeur, si bien que la première domine mécaniquement le calcul de la distance, reléguant la seconde à un rôle négligeable. La **réduction** (division de chaque variable par son écart-type s_j) ramène toutes les variables à une variance unitaire, ce qui assure que chacune contribue de manière équitable à la distance entre individus, indépendamment de son échelle de mesure initiale. C'est précisément l'objet de la sous-section suivante que de formaliser ce prétraitement et d'en préciser l'effet sur la géométrie du nuage des individus.

1.3. Prétraitement : centrage et réduction

Données centrées. On appelle matrice des données centrées la matrice $Y = (y_{ij})_{n \times p}$ où :

$$y_{ij} = x_{ij} - \bar{x}_j, \quad \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}.$$

Les colonnes de Y sont de moyenne nulle : $\bar{y}_j = 0$. Centrer les données revient à une translation du nuage des individus, qui **ne modifie pas** les distances entre eux :

$$d^2(\mathbf{x}_i, \mathbf{x}_{i'}) = d^2(\mathbf{y}_i, \mathbf{y}_{i'}).$$

Données centrées-réduites. On appelle matrice des données centrées-réduites la matrice $Z = (z_{ij})_{n \times p}$ où :

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \quad s_j^2 = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 = \frac{1}{n} \sum_{i=1}^n y_{ij}^2.$$

Les colonnes de Z sont de moyenne nulle et de variance 1 : $\bar{z}_j = 0$ et $\text{Var}(\mathbf{z}^j) = 1$. Contrairement au simple centrage, cette opération **modifie** les distances entre individus. En données centrées-réduites, la distance euclidienne entre deux individus devient :

$$d^2(\mathbf{z}_i, \mathbf{z}_{i'}) = \sum_{j=1}^p (z_{ij} - z_{i'j})^2 = \sum_{j=1}^p \frac{1}{s_j^2} (x_{ij} - x_{i'j})^2,$$

ce qui revient à pondérer chaque écart par l'inverse de la variance de la variable correspondante. Toutes les variables contribuent ainsi à la distance de manière homogène, quelle que soit leur échelle de mesure :

$$d^2(\mathbf{x}_i, \mathbf{x}_{i'}) \neq d^2(\mathbf{z}_i, \mathbf{z}_{i'}).$$

1.4. Les deux types d'ACP

On distingue deux variantes selon le prétraitement appliqué :

- **ACP non normée** : travaille sur Y et diagonalise la matrice des covariances $C = \frac{1}{n} Y^\top Y$.
- **ACP normée** : travaille sur Z et diagonalise la matrice des corrélations $R = \frac{1}{n} Z^\top Z$.

Dans la suite de ce rapport, on se place dans le cadre de l'**ACP normée**.

Pourquoi l'ACP normée ?

Le choix de l'ACP normée est standard lorsque les variables sont exprimées sur des échelles différentes ou de grandeurs incomparables. Dans ce cas, travailler sur la matrice des covariances C reviendrait à accorder un poids artificiellement plus grand aux variables à forte variance, biaisant ainsi les axes principaux. En se plaçant sur Z , toutes les variables contribuent à parts égales à l'analyse. Dans la suite de ce rapport, **toutes les définitions, propriétés et démonstrations sont établies dans le cadre de l'ACP normée.**

2. Inertie et distances

2.1. Distance euclidienne entre deux individus

La distance euclidienne a été définie en section 1.2 dans les données brutes. Appliquée aux données centrées-réduites, la distance entre deux individus i et i' (représentés respectivement par les lignes $\mathbf{z}_i$ et $\mathbf{z}_{i'}$ de Z) vaut :

$$d^2(\mathbf{z}_i, \mathbf{z}_{i'}) = \sum_{j=1}^p (z_{ij} - z_{i'j})^2 = \sum_{j=1}^p \frac{1}{s_j^2} (x_{ij} - x_{i'j})^2.$$

Chaque écart est pondéré par $1/s_j^2$, ce qui assure que toutes les variables contribuent équitablement à la distance, indépendamment de leur échelle de mesure. C'est cette distance qui sera utilisée dans toute la suite pour mesurer la dispersion du nuage des individus.

2.2. Inertie du nuage des individus

Inertie : L'inertie du nuage des individus mesure leur dispersion globale autour du barycentre G , qui est le point moyen du nuage. En données centrées-réduites, ce barycentre se calcule coordonnée par coordonnée :

$$G = \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i = \left(\frac{1}{n} \sum_{i=1}^n z_{i1}, \dots, \frac{1}{n} \sum_{i=1}^n z_{ip} \right)^\top = (0, 0, \dots, 0)^\top = \mathbf{0},$$

puisque par construction chaque colonne de Z est de moyenne nulle. Le barycentre coïncide donc avec l'origine de $\mathbb{R}^p$, ce qui explique pourquoi l'inertie se calcule comme la distance moyenne des individus à $\mathbf{0}$:

$$I(Z) = \frac{1}{n} \sum_{i=1}^n d^2(\mathbf{z}_i, \mathbf{0}).$$

Montrons que $I(Z) = \sum_{j=1}^p \text{Var}(\mathbf{z}^j) = p$.

Démonstration

On développe la distance au barycentre en utilisant la définition de la norme euclidienne :

$$I(Z) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{z}_i\|^2 = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^p z_{ij}^2.$$

En intervertissant les deux sommations (Fubini discret) :

$$I(Z) = \sum_{j=1}^p \left[\frac{1}{n} \sum_{i=1}^n z_{ij}^2 \right] = \sum_{j=1}^p \text{Var}(\mathbf{z}^j).$$

Or par définition des données centrées-réduites, $\text{Var}(\mathbf{z}^j) = 1$ pour tout $j \in \{1, \dots, p\}$, d'où :

$$I(Z) = \sum_{j=1}^p 1 = p.$$

De plus, la somme des valeurs propres d'une matrice est toujours égale à sa trace. Rappelons que la matrice des corrélations R a pour éléments $R_{jm} = \text{Cor}(\mathbf{z}^j, \mathbf{z}^m)$. En particulier,

les éléments sur la diagonale (quand $j = m$) valent :

$$R_{jj} = \text{Cor}(\mathbf{z}^j, \mathbf{z}^j) = \text{Var}(\mathbf{z}^j) = 1.$$

Donc :

$$\sum_{k=1}^r \lambda_k = \text{tr}(R) = \sum_{j=1}^p R_{jj} = \sum_{j=1}^p \text{Var}(\mathbf{z}^j) = p.$$

On obtient ainsi :

$$I(Z) = p = \sum_{k=1}^r \lambda_k.$$

où $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$ sont les valeurs propres non nulles de R et $r = \text{rang}(Z)$.

2.3. Métrique sur $\mathbb{R}^n$ et nuage des variables

Jusqu'ici, on a mesuré la proximité entre individus dans $\mathbb{R}^p$ à l'aide de la distance euclidienne standard. Pour analyser le nuage des p variables, il faut maintenant travailler dans $\mathbb{R}^n$ (chaque variable $\mathbf{z}^j$ étant un vecteur de $\mathbb{R}^n$). On se pose alors la question : quelle distance utiliser dans cet espace ?

La distance euclidienne usuelle sur $\mathbb{R}^n$ ferait intervenir une somme brute sur les n individus :

$$\|\mathbf{z}^j\|^2 = \sum_{i=1}^n z_{ij}^2.$$

Cette quantité croît mécaniquement avec n : si l'on double le nombre d'individus en gardant les mêmes données, la norme double également, ce qui rendrait les résultats non comparables d'un échantillon à l'autre. De plus, on souhaite que la norme d'une variable soit reliée à sa variance, qui est une **moyenne** sur les n individus et non une somme. En divisant par n , on obtient exactement cela :

$$\frac{1}{n} \sum_{i=1}^n z_{ij}^2 = \text{Var}(\mathbf{z}^j) = 1,$$

ce qui justifie naturellement d'introduire le facteur $\frac{1}{n}$ dans la métrique, et donc de munir $\mathbb{R}^n$ de :

$$N = \frac{1}{n} I_n.$$

Produit scalaire et norme pondérés. Le produit scalaire usuel entre deux vecteurs $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ est $\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^n x_i y_i$, ce qui correspond à prendre $N = I_n$. En substituant $N = \frac{1}{n} I_n$ à la place de I_n , on obtient un produit scalaire **pondéré**, qui moyenne la somme sur les n individus au lieu de la sommer :

$$\langle \mathbf{x}, \mathbf{y} \rangle_N = \mathbf{x}^\top N \mathbf{y} = \mathbf{x}^\top \left(\frac{1}{n} I_n \right) \mathbf{y} = \frac{1}{n} \mathbf{x}^\top \mathbf{y} = \frac{1}{n} \sum_{i=1}^n x_i y_i.$$

La norme induite par ce produit scalaire, définie par $\|\mathbf{x}\|_N = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_N}$, vaut alors :

$$\|\mathbf{x}\|_N = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}.$$

Ce choix est particulièrement judicieux car il permet d'écrire la variance et la covariance directement comme des produits scalaires ou des normes dans $(\mathbb{R}^n, N)$:

$$\text{Var}(\mathbf{z}^j) = \|\mathbf{z}^j\|_N^2 = 1, \quad \text{Cov}(\mathbf{z}^j, \mathbf{z}^m) = \langle \mathbf{z}^j, \mathbf{z}^m \rangle_N.$$

Pour la corrélation, rappelons que dans un espace muni d'un produit scalaire, l'angle θ entre deux vecteurs $\mathbf{x}$ et $\mathbf{y}$ est défini par :

$$\cos \theta = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \cdot \|\mathbf{y}\|}.$$

En adaptant cette définition à la métrique N , on appelle $\theta_N(\mathbf{z}^j, \mathbf{z}^m)$ l'angle entre $\mathbf{z}^j$ et $\mathbf{z}^m$ dans $(\mathbb{R}^n, N)$, défini par :

$$\cos \theta_N(\mathbf{z}^j, \mathbf{z}^m) = \frac{\langle \mathbf{z}^j, \mathbf{z}^m \rangle_N}{\|\mathbf{z}^j\|_N \cdot \|\mathbf{z}^m\|_N}.$$

Puisque $\|\mathbf{z}^j\|_N = \|\mathbf{z}^m\|_N = 1$, cette expression se simplifie en :

$$\cos \theta_N(\mathbf{z}^j, \mathbf{z}^m) = \langle \mathbf{z}^j, \mathbf{z}^m \rangle_N = \text{Cor}(\mathbf{z}^j, \mathbf{z}^m).$$

La corrélation entre deux variables est donc exactement le cosinus de l'angle entre leurs vecteurs dans $(\mathbb{R}^n, N)$. Puisque $\|\mathbf{z}^j\|_N = 1$, les variables centrées-réduites se trouvent toutes sur la **sphère unité** de $\mathbb{R}^n$: deux variables fortement corrélées positivement forment un angle aigu ($\theta < 90^\circ$), deux variables indépendantes forment un angle droit ($\theta = 90^\circ$), et deux variables corrélées négativement forment un angle obtus ($\theta > 90^\circ$). C'est cette propriété géométrique que l'ACP cherchera à préserver lors de la projection.

On en déduit enfin l'écriture matricielle de la matrice des corrélations :

$$R = Z^\top N Z = \frac{1}{n} Z^\top Z.$$

3. Analyse du nuage des individus

3.1. Diagonalisation de R et vecteurs propres

Conventions : indices et dimensions

La matrice des corrélations $R = \frac{1}{n} Z^\top Z$ est de taille $p \times p$ (une ligne et une colonne par variable). Étant symétrique réelle, elle possède exactement p valeurs propres réelles $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ et p vecteurs propres orthonormés $\mathbf{v}_1, \dots, \mathbf{v}_p$ qui forment une base de $\mathbb{R}^p$. L'indice $\alpha \in \{1, \dots, p\}$ numérote ces axes : $\mathbf{v}_\alpha$ et λ_α désignent le α -ème vecteur propre et la α -ème valeur propre. Ce nombre p d'axes est le nombre de variables (la dimension de $\mathbb{R}^p$), à ne pas confondre avec le nombre n d'individus. Enfin, la diagonale de R ne contient que des 1 (car $R_{jj} = \text{Var}(\mathbf{z}^j) = 1$), donc $\text{tr}(R) = p$; comme la trace égale la somme des valeurs propres, on retrouve $\sum_{\alpha=1}^p \lambda_\alpha = p$, l'inertie totale (section 2.2).

Théorème spectral : Toute matrice symétrique réelle R est diagonalisable dans une base orthonormée. Il existe donc une matrice orthogonale V et une matrice diagonale Λ telles que :

$$R = V \Lambda V^\top,$$

où $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ avec $\lambda_1 \geq \dots \geq \lambda_p \geq 0$, et $V = (\mathbf{v}_1 | \dots | \mathbf{v}_p)$ la matrice dont les colonnes sont les **vecteurs propres** orthonormés $\mathbf{v}_\alpha$ de R , vérifiant $R\mathbf{v}_\alpha = \lambda_\alpha \mathbf{v}_\alpha$.

3.2. Problème d'optimisation

On cherche les axes de projection qui conservent au mieux la variabilité du nuage des individus.

Projection orthogonale sur un axe : Soit Δ_α un axe de vecteur directeur $\mathbf{v}_\alpha \in \mathbb{R}^p$ avec $\|\mathbf{v}_\alpha\| = 1$. La projection orthogonale de l'individu i (représenté par le vecteur $\mathbf{z}_i \in \mathbb{R}^p$) sur Δ_α est le point de l'axe le plus proche de $\mathbf{z}_i$. Sa coordonnée scalaire sur cet axe est donnée par le produit scalaire usuel entre $\mathbf{z}_i$ et le vecteur directeur $\mathbf{v}_\alpha$:

$$f_{i\alpha} = \mathbf{z}_i^\top \mathbf{v}_\alpha = \sum_{j=1}^p z_{ij} v_{j\alpha}.$$

Intuitivement, si l'on projette les individus sur un axe qui capture peu de variabilité, les individus se retrouvent tous concentrés autour du même point et on perd l'information qui les distingue. À l'inverse, un axe qui maximise la variance des projections conserve au mieux les différences entre individus.

Le **premier axe principal** Δ_1 est donc l'axe de vecteur directeur $\mathbf{v}_1 \in \mathbb{R}^p$, de norme 1, qui maximise la variance des individus projetés :

$$\mathbf{v}_1 = \arg \max_{\|\mathbf{v}\|=1} \text{Var}(Z\mathbf{v}) = \arg \max_{\|\mathbf{v}\|=1} \mathbf{v}^\top R \mathbf{v}.$$

La contrainte $\|\mathbf{v}\| = 1$ est nécessaire pour que le problème soit bien posé : sans elle, on pourrait faire croître la variance indéfiniment en multipliant $\mathbf{v}$ par un scalaire arbitrairement grand.

Pour $\alpha \geq 2$, le **α -ème axe principal** Δ_α est l'axe de vecteur directeur $\mathbf{v}_\alpha \perp \mathbf{v}_1, \dots, \mathbf{v}_{\alpha-1}$ qui maximise la variance des individus projetés sous la contrainte d'orthogonalité. Cette

contrainte garantit que chaque nouvel axe apporte une information différente des précédents (deux axes orthogonaux capturent des directions de variabilité indépendantes).

3.3. Solution et composantes principales

La résolution du problème d'optimisation par la méthode des multiplicateurs de Lagrange montre que les vecteurs directeurs optimaux sont exactement les vecteurs propres de R :

Démonstration

On cherche à maximiser $\mathbf{v}^\top R \mathbf{v}$ sous $\|\mathbf{v}\|^2 = 1$. Le Lagrangien est :

$$\mathcal{L}(\mathbf{v}, \lambda) = \mathbf{v}^\top R \mathbf{v} - \lambda(\mathbf{v}^\top \mathbf{v} - 1).$$

La condition du premier ordre $\partial \mathcal{L} / \partial \mathbf{v} = \mathbf{0}$ donne :

$$2R\mathbf{v} - 2\lambda\mathbf{v} = \mathbf{0} \implies R\mathbf{v} = \lambda\mathbf{v}.$$

Donc $\mathbf{v}$ est nécessairement un vecteur propre de R . En substituant dans l'objectif : $\mathbf{v}^\top R \mathbf{v} = \lambda \|\mathbf{v}\|^2 = \lambda$. La variance est donc égale à la valeur propre λ , et elle est maximisée en prenant $\lambda = \lambda_1$ (la plus grande valeur propre) et $\mathbf{v} = \mathbf{v}_1$ (le vecteur propre associé). $\square$

On en déduit les trois propriétés fondamentales suivantes :

Propriété 1 : $\mathbf{v}_\alpha$ est le vecteur propre de R associé à λ_α .

Démonstration

Par construction du problème d'optimisation, le vecteur directeur $\mathbf{v}_\alpha$ du α -ème axe vérifie $R\mathbf{v}_\alpha = \lambda_\alpha \mathbf{v}_\alpha$: c'est exactement la définition d'un vecteur propre de R associé à λ_α . Les vecteurs $\mathbf{v}_1, \dots, \mathbf{v}_p$ forment une base orthonormée de $\mathbb{R}^p$ par le théorème spectral. $\square$

Propriété 2 : La composante principale $\mathbf{f}^\alpha = Z\mathbf{v}_\alpha$ est centrée et de variance $\text{Var}(\mathbf{f}^\alpha) = \lambda_\alpha$.

Démonstration

En projetant les n individus sur Δ_α , on obtient la α -ème **composante principale** :

$$\mathbf{f}^\alpha = Z\mathbf{v}_\alpha = \sum_{j=1}^p v_{j\alpha} \mathbf{z}^j \in \mathbb{R}^n.$$

Centrage : $\mathbf{f}^\alpha$ est une combinaison linéaire des colonnes de Z , qui sont toutes de moyenne nulle ; donc $\mathbf{f}^\alpha$ est centrée.

Variance : on utilise le résultat $\text{Var}(\mathbf{f}^\alpha) = \mathbf{v}_\alpha^\top R \mathbf{v}_\alpha$ et la propriété 1 :

$$\text{Var}(\mathbf{f}^\alpha) = \mathbf{v}_\alpha^\top R \mathbf{v}_\alpha = \mathbf{v}_\alpha^\top (\lambda_\alpha \mathbf{v}_\alpha) = \lambda_\alpha \|\mathbf{v}_\alpha\|^2 = \lambda_\alpha. \quad \square$$

Propriété 3 : Les composantes principales sont deux à deux non corrélées, c'est-à-dire que pour tout $\alpha \neq \beta$:

$$\text{Cov}(\mathbf{f}^\alpha, \mathbf{f}^\beta) = 0.$$

Démonstration

Pour $\alpha \neq \beta$, $\mathbf{v}_\alpha$ et $\mathbf{v}_\beta$ sont deux vecteurs propres d'une matrice symétrique associés à des valeurs propres distinctes : ils sont orthogonaux, $\mathbf{v}_\alpha^\top \mathbf{v}_\beta = 0$. On calcule alors la covariance :

$$\text{Cov}(\mathbf{f}^\alpha, \mathbf{f}^\beta) = \langle \mathbf{f}^\alpha, \mathbf{f}^\beta \rangle_N = \mathbf{v}_\alpha^\top R \mathbf{v}_\beta = \mathbf{v}_\alpha^\top (\lambda_\beta \mathbf{v}_\beta) = \lambda_\beta (\mathbf{v}_\alpha^\top \mathbf{v}_\beta) = \lambda_\beta \times 0 = 0. \quad \square$$

La matrice F des **coordonnées factorielles** des individus (aussi appelées *scores*) regroupe les coordonnées de tous les individus sur tous les axes principaux :

$$F = ZV, \quad V = (\mathbf{v}_1 | \dots | \mathbf{v}_q) \in \mathcal{M}_{p \times q}(\mathbb{R}).$$

F est une matrice de taille $n \times q$: chaque ligne correspond à un individu, et chaque colonne correspond à une composante principale. Plus précisément :

- La **colonne** α de F est la α -ème composante principale $\mathbf{f}^\alpha = Z\mathbf{v}_\alpha \in \mathbb{R}^n$: elle contient la coordonnée de chacun des n individus sur l'axe Δ_α .
- La **ligne** i de F est le vecteur $(f_{i1}, \dots, f_{iq})^\top$: ce sont les nouvelles coordonnées de l'individu i dans le repère factoriel.
- L'élément $f_{i\alpha}$ est la coordonnée de l'individu i sur le α -ème axe principal (c'est exactement ce qu'on représente graphiquement sur le **plan factoriel**).

Les colonnes de F sont centrées, de variances $\lambda_1 \geq \dots \geq \lambda_q$, et deux à deux non corrélées. Ainsi, on est passé de p variables originales corrélées à q composantes principales non corrélées, ordonnées par quantité d'information décroissante.

4. Analyse du nuage des variables

Dans la section 3, on a analysé le nuage des n individus dans $\mathbb{R}^p$ en cherchant les axes qui **maximisent la variance** des projections. On s'intéresse maintenant au nuage des p variables dans $\mathbb{R}^n$. Le problème change de nature : les variables ne se distinguent pas par leur position mais par les **angles** qu'elles forment entre elles, ces angles encodant leurs corrélations (section 2.3). On cherchera donc des axes qui **conservent au mieux ces angles**, c'est-à-dire qui maximisent une somme de carrés de cosinus. On verra que, malgré cette formulation différente, on retombe exactement sur les mêmes valeurs propres λ_α qu'en section 3 : c'est la **dualité** individus-variables.

4.1. Le nuage des variables et la projection sur un axe

Les variables centrées-réduites $\mathbf{z}^1, \dots, \mathbf{z}^p$ ont toutes une norme N égale à 1 (avec $N = \frac{1}{n}I_n$, la métrique de la section 2.3) : elles se trouvent donc sur la **sphère unité** de $(\mathbb{R}^n, N)$. De plus, on a établi que la corrélation entre deux variables est le cosinus de l'angle qu'elles forment dans cet espace :

$$\text{Cor}(\mathbf{z}^j, \mathbf{z}^m) = \cos \theta_N(\mathbf{z}^j, \mathbf{z}^m).$$

Analyser le nuage des variables revient donc à étudier une configuration d'angles sur la sphère unité.

Projection N -orthogonale et loadings : Soit $\mathcal{G}_\alpha$ un axe de vecteur directeur $\mathbf{u}_\alpha \in \mathbb{R}^n$ avec $\|\mathbf{u}_\alpha\|_N = 1$. La projection N -orthogonale de la variable $\mathbf{z}^j$ sur $\mathcal{G}_\alpha$ est le point de l'axe le plus proche de $\mathbf{z}^j$ au sens de la métrique N . Sa coordonnée scalaire est :

$$a_{j\alpha} = \langle \mathbf{z}^j, \mathbf{u}_\alpha \rangle_N = (\mathbf{z}^j)^\top N \mathbf{u}_\alpha = \frac{1}{n} \sum_{i=1}^n z_{ij} u_{i\alpha}.$$

Les scalaires $a_{j\alpha}$ sont les **loadings**. Le point essentiel, qui motive toute la suite, est que ce loading **est exactement un cosinus** : puisque $\|\mathbf{z}^j\|_N = 1$ et $\|\mathbf{u}_\alpha\|_N = 1$,

$$a_{j\alpha} = \langle \mathbf{z}^j, \mathbf{u}_\alpha \rangle_N = \frac{\langle \mathbf{z}^j, \mathbf{u}_\alpha \rangle_N}{\|\mathbf{z}^j\|_N \|\mathbf{u}_\alpha\|_N} = \cos \theta_N(\mathbf{z}^j, \mathbf{u}_\alpha).$$

À axe fixé, on regroupe ces loadings dans le vecteur $\mathbf{a}^\alpha = Z^\top N \mathbf{u}_\alpha \in \mathbb{R}^p$.

4.2. Problème d'optimisation : maximiser les $\cos^2$

La qualité de représentation de la variable $\mathbf{z}^j$ sur un axe $\mathcal{G}_\alpha$ se mesure par $\cos^2 \theta_N(\mathbf{z}^j, \mathbf{u}_\alpha)$: elle vaut 1 si la variable est colinéaire à l'axe (parfaitement représentée) et 0 si elle lui est orthogonale (pas du tout représentée). On cherche donc l'axe qui maximise la somme de ces qualités sur l'ensemble des variables.

Premier axe du nuage des variables :

$$\mathbf{u}_1 = \arg \max_{\|\mathbf{u}\|_N=1} \sum_{j=1}^p \cos^2 \theta_N(\mathbf{z}^j, \mathbf{u}).$$

Comme le loading est un cosinus, cette somme se réécrit comme une norme :

$$\sum_{j=1}^p \cos^2 \theta_N(\mathbf{z}^j, \mathbf{u}) = \sum_{j=1}^p \langle \mathbf{z}^j, \mathbf{u} \rangle_N^2 = \sum_{j=1}^p \left((Z^\top N \mathbf{u})_j \right)^2 = \|Z^\top N \mathbf{u}\|^2,$$

de sorte que le problème équivaut à :

$$\mathbf{u}_1 = \arg \max_{\|\mathbf{u}\|_N=1} \|Z^\top N \mathbf{u}\|^2.$$

Maximiser la somme des $\cos^2$ revient à chercher l'axe en moyenne le moins éloigné angulairement de l'ensemble des variables : c'est l'axe qui résume le mieux leurs corrélations. Pour $\alpha \geq 2$, le α -ème axe $\mathcal{G}_\alpha$ maximise la même quantité sous la contrainte $\mathbf{u}_\alpha \perp_N \mathbf{u}_1, \dots, \mathbf{u}_{\alpha-1}$, garantissant que chaque axe apporte une information angulaire nouvelle.

Le même résultat, un problème différent

C'est ici que se lit la dualité avec la section 3 :

- **Nuage des individus (sec. 3)** : on maximise la variance $\mathbf{v}^\top R \mathbf{v}$ des projections, dans $(\mathbb{R}^p, I_p)$.
- **Nuage des variables (sec. 4)** : on maximise la somme des $\cos^2$ $\|Z^\top N \mathbf{u}\|^2$ des angles, dans $(\mathbb{R}^n, N)$.

Deux objectifs distincts, deux espaces distincts — mais on va voir qu'ils partagent les mêmes valeurs propres λ_α .

4.3. Solution : vecteurs propres de $\frac{1}{n}ZZ^\top$

Résolution par Lagrange : On maximise $\|Z^\top N \mathbf{u}\|^2 = \mathbf{u}^\top NZZ^\top N \mathbf{u}$ sous $\|\mathbf{u}\|_N^2 = \mathbf{u}^\top N \mathbf{u} = 1$. Le Lagrangien est :

$$\mathcal{L}(\mathbf{u}, \mu) = \mathbf{u}^\top NZZ^\top N \mathbf{u} - \mu(\mathbf{u}^\top N \mathbf{u} - 1).$$

La condition du premier ordre donne :

$$2NZZ^\top N \mathbf{u} - 2\mu N \mathbf{u} = \mathbf{0} \implies \frac{1}{n}ZZ^\top \mathbf{u} = \mu \mathbf{u}.$$

Donc $\mathbf{u}_\alpha$ est vecteur propre de $\frac{1}{n}ZZ^\top$ associé à la valeur propre $\mu = \lambda_\alpha$. En réinjectant dans l'objectif, sa valeur optimale vaut exactement λ_α .

Lien entre $\frac{1}{n}ZZ^\top$ et $R = \frac{1}{n}Z^\top Z$: Ces deux matrices n'ont pas la même taille ($n \times n$ contre $p \times p$) mais partagent les mêmes valeurs propres non nulles. C'est le résultat central qui unifie les sections 3 et 4. En effet, si $R\mathbf{v} = \lambda\mathbf{v}$, alors en posant $\mathbf{u} = Z\mathbf{v}$:

$$\frac{1}{n}ZZ^\top \mathbf{u} = \frac{1}{n}ZZ^\top Z\mathbf{v} = Z \underbrace{\left(\frac{1}{n}Z^\top Z\right)}_R \mathbf{v} = Z(\lambda\mathbf{v}) = \lambda\mathbf{u}.$$

Donc $\mathbf{u} = Z\mathbf{v}$ est vecteur propre de $\frac{1}{n}ZZ^\top$ pour la même valeur propre λ . Les deux analyses reposent ainsi sur le **même** spectre λ_α , ce qui garantit la cohérence de l'ACP : la variance maximale captée côté individus égale la somme des $\cos^2$ maximale captée côté variables.

Interprétation des valeurs propres : La valeur optimale de l'objectif étant λ_α , on obtient :

$$\lambda_\alpha = \sum_{j=1}^p \cos^2 \theta_N(\mathbf{z}^j, \mathbf{u}_\alpha) = \sum_{j=1}^p a_{j\alpha}^2 = \|\mathbf{a}^\alpha\|^2.$$

Chaque valeur propre λ_α est donc la somme des qualités de représentation de toutes les variables sur l'axe $\mathcal{G}_\alpha$ (c'est une somme **sur l'indice** j , à axe fixé). On en déduit en particulier $\|\mathbf{a}^\alpha\| = \sqrt{\lambda_\alpha}$: plus λ_α est grande, mieux les variables sont collectivement représentées sur cet axe.

4.4. Position des variables dans le plan factoriel

La valeur $\|\mathbf{a}^\alpha\| = \sqrt{\lambda_\alpha}$ ci-dessus agrège toutes les variables sur un axe ; elle ne situe pas une variable donnée. Pour cela, on raisonne à variable fixée.

(i) **Chaque coordonnée est dans $[-1, 1]$.** Par Cauchy-Schwarz dans $(\mathbb{R}^n, N)$, et puisque $\|\mathbf{z}^j\|_N = \|\mathbf{u}_\alpha\|_N = 1$:

$$|a_{j\alpha}| = |\langle \mathbf{z}^j, \mathbf{u}_\alpha \rangle_N| \leq \|\mathbf{z}^j\|_N \|\mathbf{u}_\alpha\|_N = 1,$$

avec égalité si et seulement si $\mathbf{z}^j$ et $\mathbf{u}_\alpha$ sont colinéaires.

(ii) **La somme des carrés sur les axes vaut 1.** Les vecteurs $\mathbf{u}_1, \dots, \mathbf{u}_r$ forment une base N -orthonormée de l'espace engendré par les colonnes de Z , auquel $\mathbf{z}^j$ appartient. L'égalité de Parseval donne :

$$\sum_{\alpha=1}^r a_{j\alpha}^2 = \|\mathbf{z}^j\|_N^2 = 1.$$

En conservant tous les axes, $\mathbf{z}^j$ est exactement sur la sphère unité ; en n'en gardant que deux, son point projeté est à la distance $\sqrt{a_{j1}^2 + a_{j2}^2} \leq 1$ de l'origine. La variable tombe donc **à l'intérieur** du cercle unité, et n'atteint le bord que si elle est parfaitement représentée par les deux premiers axes.

Deux sommes de carrés à ne pas confondre

$$\underbrace{\sum_{j=1}^p a_{j\alpha}^2 = \lambda_\alpha}_{\text{axe } \alpha \text{ fixé : qualité de l'axe}} \quad \text{contre} \quad \underbrace{\sum_{\alpha=1}^r a_{j\alpha}^2 = 1}_{\text{variable } j \text{ fixée : norme de la variable}}$$

Le rayon du cercle des corrélations est **1** (somme sur les axes), **et non** $\sqrt{\lambda_\alpha}$. La quantité $\sqrt{\lambda_\alpha} = \|\mathbf{a}^\alpha\|$ est la norme du vecteur des loadings d'un axe et n'a pas de rapport avec la position d'une variable.

On représente donc chaque variable par le couple (a_{j1}, a_{j2}) . On démontrera en section 5.2 que ces loadings sont exactement les corrélations entre variables et composantes principales,

$$a_{j\alpha} = \text{Cor}(\mathbf{x}^j, \mathbf{f}^\alpha) \in [-1, 1],$$

ce qui fonde l'interprétation du **cercle des corrélations** (cercle unité du plan) : une variable proche du bord est bien représentée, une variable proche du centre est mal projetée et ne doit pas être interprétée. Enfin, les vecteurs propres $\mathbf{v}_\alpha$ de R (section 3) et $\mathbf{u}_\alpha$ de $\frac{1}{n}ZZ^\top$ (section 4) sont reliés par les **formules de passage** de la section suivante.

5. Formules de passage et SVD

5.1. Lien entre les deux nuages

On a vu en sections 3 et 4 que les deux analyses (nuage des individus et nuage des variables) partagent les mêmes valeurs propres λ_α . Il reste à établir le lien explicite entre les objets des deux analyses : les vecteurs $\mathbf{v}_\alpha \in \mathbb{R}^p$ (vecteurs propres de R , espace des variables) et $\mathbf{u}_\alpha \in \mathbb{R}^n$ (vecteurs propres de $\frac{1}{n}ZZ^\top$, espace des individus).

On note $A = (\mathbf{a}^1 | \dots | \mathbf{a}^q) \in \mathcal{M}_{p \times q}(\mathbb{R})$ la matrice des loadings, dont l'élément (j, α) est le loading $a_{j\alpha}$ de la variable j sur l'axe α . De même, on rappelle que $F = (\mathbf{f}^1 | \dots | \mathbf{f}^q) \in \mathcal{M}_{n \times q}(\mathbb{R})$ est la matrice des coordonnées factorielles des individus (définie en section 3.3).

Formules de passage : Les vecteurs $\mathbf{v}_\alpha$ et $\mathbf{u}_\alpha$ sont liés par :

$$\mathbf{f}^\alpha = Z\mathbf{v}_\alpha = \sqrt{\lambda_\alpha} \mathbf{u}_\alpha \quad \text{et} \quad \mathbf{a}^\alpha = Z^\top N \mathbf{u}_\alpha = \sqrt{\lambda_\alpha} \mathbf{v}_\alpha.$$

$$\begin{aligned} \text{En notation matricielle : } F &= U\Lambda^{1/2} \text{ et} \\ A &= V\Lambda^{1/2}, \text{ avec } \Lambda^{1/2} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_q}). \end{aligned}$$

Démonstration

Première formule : $Z\mathbf{v}_\alpha = \sqrt{\lambda_\alpha} \mathbf{u}_\alpha$.

On a montré en section 4.3 que si $R\mathbf{v}_\alpha = \lambda_\alpha \mathbf{v}_\alpha$, alors $\mathbf{u} = Z\mathbf{v}_\alpha$ est vecteur propre de $\frac{1}{n}ZZ^\top$ pour la même valeur propre λ_α . Il reste à vérifier la normalisation. On calcule la norme N de $Z\mathbf{v}_\alpha$:

$$\begin{aligned} \|Z\mathbf{v}_\alpha\|_N^2 &= \frac{1}{n} (Z\mathbf{v}_\alpha)^\top (Z\mathbf{v}_\alpha) = \frac{1}{n} \mathbf{v}_\alpha^\top Z^\top Z \mathbf{v}_\alpha = \mathbf{v}_\alpha^\top \underbrace{\left(\frac{1}{n} Z^\top Z \right)}_R \mathbf{v}_\alpha \\ &= \mathbf{v}_\alpha^\top (\lambda_\alpha \mathbf{v}_\alpha) = \lambda_\alpha \|\mathbf{v}_\alpha\|^2 = \lambda_\alpha. \end{aligned}$$

Donc $\|Z\mathbf{v}_\alpha\|_N = \sqrt{\lambda_\alpha}$. Or $\mathbf{u}_\alpha$ est normalisé : $\|\mathbf{u}_\alpha\|_N = 1$. On en déduit :

$$Z\mathbf{v}_\alpha = \sqrt{\lambda_\alpha} \mathbf{u}_\alpha. \quad \square$$

Deuxième formule : $Z^\top N \mathbf{u}_\alpha = \sqrt{\lambda_\alpha} \mathbf{v}_\alpha$.

On substitue $\mathbf{u}_\alpha = Z\mathbf{v}_\alpha / \sqrt{\lambda_\alpha}$:

$$\begin{aligned} Z^\top N \mathbf{u}_\alpha &= Z^\top N \frac{Z\mathbf{v}_\alpha}{\sqrt{\lambda_\alpha}} = \frac{1}{\sqrt{\lambda_\alpha}} Z^\top N Z \mathbf{v}_\alpha = \frac{1}{\sqrt{\lambda_\alpha}} \underbrace{\left(Z^\top \frac{1}{n} Z \right)}_R \mathbf{v}_\alpha \\ &= \frac{1}{\sqrt{\lambda_\alpha}} R \mathbf{v}_\alpha = \frac{\lambda_\alpha}{\sqrt{\lambda_\alpha}} \mathbf{v}_\alpha = \sqrt{\lambda_\alpha} \mathbf{v}_\alpha. \quad \square \end{aligned}$$

Interprétation des formules de passage

Ces deux formules montrent que les deux analyses sont parfaitement cohérentes :

- $\mathbf{f}^\alpha = \sqrt{\lambda_\alpha} \mathbf{u}_\alpha$: la composante principale est proportionnelle au vecteur propre de $\frac{1}{n} Z Z^\top$. Connaître $\mathbf{v}_\alpha$ suffit à calculer $\mathbf{u}_\alpha$ et $\mathbf{f}^\alpha$.
- $\mathbf{a}^\alpha = \sqrt{\lambda_\alpha} \mathbf{v}_\alpha$: le vecteur des loadings est proportionnel au vecteur propre de R . Connaître $\mathbf{u}_\alpha$ suffit à calculer $\mathbf{v}_\alpha$ et $\mathbf{a}^\alpha$.

En pratique, il suffit donc de résoudre **un seul** des deux problèmes aux valeurs propres pour obtenir tous les résultats de l'ACP.

5.2. Les loadings sont des corrélations

Résultat fondamental : Les loadings $a_{j\alpha}$ sont égaux aux corrélations entre les variables originelles et les composantes principales :

$$a_{j\alpha} = \text{Cor}(\mathbf{x}^j, \mathbf{f}^\alpha).$$

Démonstration

On procède en deux étapes.

Étape 1 : On exprime $a_{j\alpha}$ en fonction de $v_{j\alpha}$. D'après la formule de passage $\mathbf{a}^\alpha = \sqrt{\lambda_\alpha} \mathbf{v}_\alpha$, la j -ème coordonnée donne :

$$a_{j\alpha} = \sqrt{\lambda_\alpha} v_{j\alpha}.$$

Étape 2 : On calcule $\text{Cor}(\mathbf{z}^j, \mathbf{f}^\alpha)$. Puisque $\|\mathbf{z}^j\|_N = 1$ et $\|\mathbf{f}^\alpha / \sqrt{\lambda_\alpha}\|_N = \|\mathbf{u}_\alpha\|_N = 1$, la corrélation s'écrit comme un produit scalaire N :

$$\text{Cor}(\mathbf{z}^j, \mathbf{f}^\alpha) = \langle \mathbf{z}^j, \frac{\mathbf{f}^\alpha}{\sqrt{\lambda_\alpha}} \rangle_N = \frac{1}{\sqrt{\lambda_\alpha}} \langle \mathbf{z}^j, \mathbf{f}^\alpha \rangle_N = \frac{1}{\sqrt{\lambda_\alpha}} (Z^\top N Z \mathbf{v}_\alpha)_j = \frac{1}{\sqrt{\lambda_\alpha}} (R \mathbf{v}_\alpha)_j.$$

Or $R \mathbf{v}_\alpha = \lambda_\alpha \mathbf{v}_\alpha$, donc :

$$\text{Cor}(\mathbf{z}^j, \mathbf{f}^\alpha) = \frac{\lambda_\alpha v_{j\alpha}}{\sqrt{\lambda_\alpha}} = \sqrt{\lambda_\alpha} v_{j\alpha} = a_{j\alpha}. \quad \square$$

Importance pour l'interprétation

Ce résultat est fondamental : les loadings $a_{j\alpha} \in [-1, 1]$ donnent directement la corrélation entre chaque variable x^j et chaque composante principale $\mathbf{f}^\alpha$. C'est sur ce résultat que repose toute l'interprétation du cercle des corrélations : la coordonnée de la variable j sur l'axe α dans le cercle des corrélations est exactement sa corrélation avec la α -ème composante principale.

5.3. Décomposition en Valeurs Singulières (SVD)

En pratique, l'ACP n'utilise pas la diagonalisation directe de R , car calculer $R = \frac{1}{n} Z^\top Z$ puis la diagonaliser introduit des erreurs numériques importantes lorsque p est grand. On préfère utiliser la **décomposition en valeurs singulières (SVD)** de Z directement, qui est numériquement plus stable.

Décomposition en Valeurs Singulières : Toute matrice $Z \in \mathcal{M}_{n \times p}(\mathbb{R})$ de rang r admet une décomposition de la forme :

$$Z = U\Delta V^\top,$$

où :

- $U \in \mathcal{M}_{n \times r}(\mathbb{R})$ est à colonnes orthonormées : ses colonnes $\mathbf{u}_1, \dots, \mathbf{u}_r$ sont les vecteurs propres de $\frac{1}{n}ZZ^\top$,
- $V \in \mathcal{M}_{p \times r}(\mathbb{R})$ est à colonnes orthonormées : ses colonnes $\mathbf{v}_1, \dots, \mathbf{v}_r$ sont les vecteurs propres de R ,
- $\Delta = \text{diag}(\delta_1, \dots, \delta_r)$ avec $\delta_1 \geq \dots \geq \delta_r > 0$ les **valeurs singulières** de Z .

Lien avec les valeurs propres de R : Les valeurs propres de R s'obtiennent directement à partir des valeurs singulières :

$$\lambda_k = \frac{\delta_k^2}{n}.$$

Démonstration

On calcule $R = \frac{1}{n}Z^\top Z$ en substituant $Z = U\Delta V^\top$:

$$R = \frac{1}{n}Z^\top Z = \frac{1}{n}(U\Delta V^\top)^\top (U\Delta V^\top) = \frac{1}{n}V\Delta^\top U^\top U\Delta V^\top.$$

Or $U^\top U = I_r$ car U est à colonnes orthonormées, et $\Delta^\top = \Delta$ car Δ est diagonale. Donc :

$$R = \frac{1}{n}V\Delta^2 V^\top = V \underbrace{\left(\frac{1}{n}\Delta^2\right)}_{\Lambda} V^\top,$$

où $\Lambda = \text{diag}(\delta_1^2/n, \dots, \delta_r^2/n)$. On reconnaît la diagonalisation de R , donc :

$$\lambda_k = \frac{\delta_k^2}{n}. \quad \square$$

6. Interprétation des résultats

6.1. Qualité de la réduction de dimension

Une fois les composantes principales calculées, il faut évaluer combien d'entre elles retenir. Le critère naturel est de mesurer quelle fraction de l'information totale (l'inertie p) est capturée par les q premières composantes.

Inertie expliquée. On a montré en section 2.2 que l'inertie totale vaut $p = \sum_{k=1}^r \lambda_k$. La composante principale $\mathbf{f}^\alpha$ capture une variance égale à λ_α (propriété 2, section 3.3). La **proportion d'inertie expliquée** par la α -ème composante est donc :

$$\tau_\alpha = \frac{\lambda_\alpha}{p} \in [0, 1].$$

Plus τ_α est proche de 1, plus la α -ème composante est à elle seule informative. La **proportion cumulée** sur les q premières composantes mesure la qualité globale de la réduction à q dimensions :

$$\tau_{1:q} = \frac{\lambda_1 + \dots + \lambda_q}{p}.$$

En pratique, on cherche q tel que $\tau_{1:q}$ soit suffisamment élevé, typiquement supérieur à 80%.

6.2. Qualité de représentation des individus

Projeter les individus sur q axes au lieu de p introduit nécessairement une perte d'information. Pour chaque individu, on mesure à quel point sa projection est fidèle à sa position originale dans $\mathbb{R}^p$.

Cosinus carré d'un individu. L'individu i est représenté par $\mathbf{z}_i \in \mathbb{R}^p$. Sa projection sur l'axe Δ_α a pour coordonnée $f_{i\alpha}$. La qualité de cette projection se mesure par le cosinus carré de l'angle $\theta_{i\alpha}$ entre $\mathbf{z}_i$ et l'axe Δ_α :

$$\cos^2(\theta_{i\alpha}) = \frac{f_{i\alpha}^2}{\|\mathbf{z}_i\|^2}.$$

Ce rapport compare la distance de l'individu à l'origine **sur l'axe** ($f_{i\alpha}^2$) à sa distance totale à l'origine ($\|\mathbf{z}_i\|^2$). Plus ce cosinus est proche de 1, plus l'individu est bien représenté sur cet axe. Sur le plan $(\Delta_\alpha, \Delta_{\alpha'})$, la qualité de représentation est $\cos^2(\theta_{i\alpha}) + \cos^2(\theta_{i\alpha'})$.

Un individu proche de l'origine du plan factoriel a des coordonnées $f_{i\alpha}$ faibles pour tous les axes : il est mal représenté et ne doit pas être interprété.

Contribution d'un individu. Le cosinus carré mesure la qualité de représentation d'un individu, mais pas son importance dans la construction de l'axe. La **contribution** de l'individu i à l'inertie de l'axe Δ_α mesure dans quelle mesure cet individu a *tiré* l'axe vers lui :

$$\text{Ctr}(i, \alpha) = \frac{f_{i\alpha}^2}{n\lambda_\alpha}, \quad \text{avec} \quad \sum_{i=1}^n \text{Ctr}(i, \alpha) = 1.$$

Cette formule se comprend ainsi : $f_{i\alpha}^2$ mesure l'éloignement de l'individu i sur l'axe, et on normalise par $n\lambda_\alpha = n \cdot \text{Var}(\mathbf{f}^\alpha)$ pour obtenir une contribution relative. Les individus ayant une forte contribution sont ceux qui sont à la fois **excentrés** (loin de l'origine) et **bien représentés** (cosinus carré élevé) : ce sont eux qui ont le plus influencé la direction de l'axe.

6.3. Qualité de représentation des variables – Cercle des corrélations

Cosinus carré d'une variable. De la même manière que pour les individus, on mesure la qualité de représentation de la variable j sur l'axe $\mathcal{G}_\alpha$ par le cosinus carré de l'angle entre $\mathbf{z}^j$ et $\mathcal{G}_\alpha$. En ACP normée, $\|\mathbf{z}^j\|_N = 1$, donc :

$$\cos^2(\theta_{j\alpha}) = \frac{a_{j\alpha}^2}{\|\mathbf{z}^j\|_N^2} = \frac{a_{j\alpha}^2}{1} = a_{j\alpha}^2.$$

Le cosinus carré est donc directement le carré du loading, c'est-à-dire le carré de la corrélation entre la variable et la composante principale : $\cos^2(\theta_{j\alpha}) = \text{Cor}(x^j, \mathbf{f}^\alpha)^2$. La qualité de représentation sur le plan $(\mathcal{G}_\alpha, \mathcal{G}_{\alpha'})$ est :

$$\cos^2(\theta_{j\alpha}) + \cos^2(\theta_{j\alpha'}) = a_{j\alpha}^2 + a_{j\alpha'}^2.$$

Contribution d'une variable. La contribution de la variable j à l'inertie de l'axe $\mathcal{G}_\alpha$ est :

$$\text{Ctr}(j, \alpha) = \frac{a_{j\alpha}^2}{\lambda_\alpha}, \quad \text{avec} \quad \sum_{j=1}^p \text{Ctr}(j, \alpha) = 1.$$

On vérifie bien que $\sum_{j=1}^p \text{Ctr}(j, \alpha) = \frac{1}{\lambda_\alpha} \sum_{j=1}^p a_{j\alpha}^2 = \frac{\lambda_\alpha}{\lambda_\alpha} = 1$, en utilisant le résultat de la section 4.3 : $\sum_{j=1}^p a_{j\alpha}^2 = \lambda_\alpha$.

Lecture du cercle des corrélations

Les variables sont représentées par des vecteurs dans le plan factoriel $(\mathcal{G}_1, \mathcal{G}_2)$. Trois règles de lecture :

- **Longueur du vecteur** = $\sqrt{a_{j1}^2 + a_{j2}^2}$: mesure la qualité de représentation dans le plan. Une variable dont le vecteur atteint le bord du cercle (longueur ≈ 1) est parfaitement représentée ; une variable proche du centre est mal projetée et ne doit pas être interprétée.
- **Angle entre deux vecteurs** : un angle aigu ($\theta < 90^\circ$) indique une corrélation positive ; un angle droit ($\theta = 90^\circ$) indique des variables non corrélées ; un angle obtus ($\theta > 90^\circ$) indique une corrélation négative.
- **Coordonnée sur un axe** : la coordonnée de la variable j sur l'axe α vaut $a_{j\alpha} = \text{Cor}(x^j, \mathbf{f}^\alpha)$ — c'est directement sa corrélation avec la α -ème composante principale.

7. Choix du nombre de composantes à retenir

Retenir trop peu de composantes fait perdre de l'information ; en retenir trop rend l'interprétation difficile et introduit du bruit. Plusieurs critères permettent de déterminer le nombre optimal q de composantes à retenir. Ils reposent tous sur l'analyse des valeurs propres $\lambda_1 \geq \dots \geq \lambda_r$.

Règle du coude de Cattell. On trace l'éboulis des valeurs propres (*scree plot*) : c'est le graphique qui représente λ_k en fonction de k . Les premières valeurs propres décroissent rapidement (elles captent l'essentiel de l'information), puis la décroissance ralentit et devient régulière (les axes suivants n'apportent plus grand chose). On cherche le **coude**, c'est-à-dire le point où la décroissance ralentit nettement — on retient les composantes situées avant ce coude.

On peut formaliser cette détection en calculant les différences secondes :

$$\delta_\alpha = (\lambda_\alpha - \lambda_{\alpha+1}) - (\lambda_{\alpha+1} - \lambda_{\alpha+2}),$$

et en retenant q tel que δ_q change de signe : cela correspond au point d'inflexion de la courbe.

Règle de Kaiser-Guttman. On ne retient que les composantes dont la valeur propre dépasse la moyenne des valeurs propres, qui vaut 1 en ACP normée (puisque $\sum_{k=1}^p \lambda_k = p$) :

$$q = \#\{k : \lambda_k > 1\}.$$

L'intuition est la suivante : si les p variables étaient toutes indépendantes, toutes les valeurs propres vaudraient 1 — chaque axe n'expliquerait qu'une seule variable. Un axe principal doit donc expliquer **plus qu'une variable isolée** pour justifier d'être retenu.

Règle de Karlis-Saporta-Spinaki. La règle de Kaiser-Guttman ne tient pas compte de la taille de l'échantillon n ni du nombre de variables p . La règle de Karlis-Saporta-Spinaki est une version plus stricte qui corrige ce défaut en ajoutant un seuil qui dépend de n et p :

$$\lambda_k > 1 + 2\sqrt{\frac{p-1}{n-1}}.$$

Plus n est grand devant p , plus ce seuil se rapproche de 1 et coïncide avec la règle de Kaiser-Guttman. Plus p est grand devant n , plus le seuil est élevé et la règle est sélective.

Test des bâtons brisés. Ce critère repose sur une analogie : si on casse un bâton de longueur p en p morceaux de manière aléatoire, quelle longueur attend-on pour le k -ème plus grand morceau ? Si les valeurs propres ne dépassent pas ce seuil aléatoire, les axes correspondants ne capturent pas plus d'information qu'on ne l'attendrait par hasard. Le seuil théorique est :

$$b_k = \sum_{m=k}^p \frac{1}{m}, \quad \text{la composante } k \text{ est retenue si } \lambda_k > b_k.$$

Analyse parallèle. C'est la méthode la plus rigoureuse. L'idée est de comparer les valeurs propres observées à celles qu'on obtiendrait si les données ne contenaient **aucune structure** (variables indépendantes). Si une valeur propre observée ne dépasse pas ce seuil aléatoire, l'axe correspondant ne capture rien de réel.

On procède ainsi :

1. Permuter aléatoirement les valeurs à l'intérieur de chaque colonne de Z indépendamment $\Rightarrow$ les corrélations entre variables sont détruites, mais les distributions marginales sont conservées.
2. Réaliser l'ACP sur ces données permutées et collecter les valeurs propres $\lambda_k^{(t)}$.
3. Répéter T fois (typiquement $T = 1000$) et calculer pour chaque k la moyenne μ_k (ou le quantile 0,95 pour un test plus conservateur).
4. Retenir la composante k si $\lambda_k > \mu_k$: la valeur propre observée dépasse ce qu'on obtiendrait par hasard.

Quel critère choisir en pratique ?

Les quatre critères ne donnent pas toujours le même q . En pratique :

- La **règle de Kaiser-Guttman** est la plus utilisée car simple à calculer, mais tend à retenir trop de composantes.
- La **règle du coude** est utile visuellement mais subjective.
- L'**analyse parallèle** est la plus rigoureuse statistiquement et est recommandée quand n et p sont grands.
- On peut aussi combiner plusieurs critères et retenir q tel que $\tau_{1:q} \geq 80\%$ (section 6.1).

8. Applications numériques

Pour illustrer la démarche complète de l'ACP, on traite deux jeux de données complémentaires. Le premier, *iris*, est un cas d'école : peu de variables, une structure très marquée, et tous les critères de choix du nombre de composantes qui convergent. Le second, *decathlon*, est plus réaliste : les variables sont exprimées dans des unités réellement différentes (ce qui rend l'ACP normée indispensable), la structure est plus diffuse, et les critères de choix divergent. Dans les deux cas, on suit le même plan : présentation des données, valeurs propres et choix de q , cercle des corrélations, plan des individus.

8.1. Premier exemple : le jeu de données Iris

8.1.1. Présentation des données

Le jeu *iris*, introduit par Ronald Fisher en 1936, contient $n = 150$ fleurs d'iris décrites par $p = 4$ variables quantitatives : la longueur et la largeur du sépale (*Sepal.Length*, *Sepal.Width*) et du pétale (*Petal.Length*, *Petal.Width*), toutes en centimètres. Les fleurs se répartissent en trois espèces (50 chacune) : *Iris setosa*, *Iris versicolor* et *Iris virginica*. Bien qu'exprimées dans la même unité, les variables ont des ordres de grandeur différents : on applique une **ACP normée**.

8.1.2. Mise en œuvre sous R

```
library(FactoMineR) library(factoextra)
data(iris) res.iris <- PCA(iris, scale.unit = TRUE, quali.sup = 5, graph =
FALSE) res.iris$eig
```

La variable *Species* (colonne 5), qualitative, est déclarée en **supplémentaire** (*quali.sup* = 5) : elle ne participe pas à la construction des axes mais servira à colorer le plan des individus.

8.1.3. Analyse des valeurs propres

Composante	λ_k	τ_k (%)	$\tau_{1:k}$ (%)
1	2,918	72,96	72,96
2	0,914	22,85	95,81
3	0,147	3,67	99,48
4	0,021	0,52	100,00

On vérifie d'abord la cohérence avec la théorie : la somme des valeurs propres vaut $4 = p$, ce qui confirme l'ACP normée (section 2.2) :

```
> sum(res.iris$eig[,1]) [1] 4
```

Choix du nombre de composantes. Tous les critères convergent vers $q = 2$:

- **Proportion cumulée** : $\tau_{1:2} = 95,81\% > 80\%$;
- **Règle du coude** : l'éboulis (figure 1) casse nettement après la dimension 2 ;
- **Règle de Kaiser-Guttman** : $\lambda_1 = 2,92 > 1$, et $\lambda_2 = 0,91$ en est très proche.

On retient $q = 2$ **composantes**, qui résument 95,81% de l'information.




FIGURE 1 – Éboulis des valeurs propres – Iris

8.1.4. Cercle des corrélations

```
fviz_pca_var(res.iris, col.var = "cos2", gradient.cols = c("brown",
"orange", "blue"), repel = TRUE)
```




FIGURE 2 – Cercle des corrélations – Iris

Sur l'axe 1 (73%), les variables `Petal.Length`, `Petal.Width` et `Sepal.Length` pointent vers la droite : elles sont liées à cet axe, qui représente donc la **taille générale de la fleur** — longueur et largeur du pétale, plus longueur du sépale, augmentent ensemble. Ces trois variables forment deux à deux des angles aigus : elles sont corrélées positivement, les

deux variables de pétale très fortement (flèches quasi confondues), `Sepal.Length` un peu moins nettement (sa flèche, plus grise, indique un $\cos^2$ plus faible dans ce plan). Sur l'axe 2 (22,9%), seule `Sepal.Width` est présente : cet axe représente la **largeur du sépale**. Enfin, `Sepal.Width` et `Sepal.Length` ont des directions quasi orthogonales : ces deux variables sont non corrélées.

8.1.5. Plan des individus

```
fviz_pca_ind(res.iris, habillage = iris$species, col.ind = "cos2", palette = c("blue", "orange", "red"), addEllipses = TRUE, label = "none", repel = TRUE)
```




FIGURE 3 – Plan des individus coloré par espèce – Iris

Les trois espèces se séparent nettement, principalement sur l'**axe 1** : *setosa* à gauche, *versicolor* au milieu, *virginica* à droite. *Setosa* est la plus distincte ; *versicolor* et *virginica* se chevauchent légèrement (leurs ellipses se touchent), ce qui traduit une plus grande proximité entre ces deux espèces. Comme l'axe 1 mesure la taille de la fleur, une espèce située à droite a de grandes fleurs et à gauche de petites : *setosa* a les plus petits pétales, *virginica* les plus grands, *versicolor* est intermédiaire. L'axe 2 ne discrimine pas les espèces : la largeur du sépale n'est pas un critère qui les distingue.

Bilan – Iris

En réduisant 4 variables à 2 composantes capturant 95,81% de l'inertie, l'ACP révèle une structure entre espèces invisible dans l'espace original. *Setosa* est séparable dès le premier axe ; *versicolor* et *virginica* demandent un examen plus fin. Tous les critères s'accordant sur $q = 2$, Iris constitue un cas « idéal » d'application de l'ACP.

8.2. Deuxième exemple : le jeu de données Decathlon

8.2.1. Présentation des données

Le jeu `decathlon` du package `FactoMineR` regroupe les performances de $n = 41$ athlètes lors de deux compétitions de décathlon (le Décastar et les Jeux Olympiques 2004). Chaque athlète est décrit par $p = 10$ variables quantitatives, une par épreuve :

- épreuves de course : `100m`, `400m`, `110m.hurdle`, `1500m` (en secondes) ;
- épreuves de saut : `Long.jump`, `High.jump`, `Pole.vault` (en mètres) ;
- épreuves de lancer : `Shot.put`, `Discus`, `Javeline` (en mètres).

S'y ajoutent trois variables **supplémentaires** : le nombre de points (`Points`) et le classement (`Rank`), quantitatives (`quanti.sup`), et la compétition (`Competition`), qualitative (`quali.sup`).

Contrairement à Iris, où toutes les variables étaient en centimètres, les épreuves sont ici mesurées dans des **unités réellement différentes** (secondes et mètres) : une ACP non normée serait dominée par les variables à forte variance. L'ACP **normée** est donc indispensable.

Attention au sens des variables de course

Pour les courses (`100m`, `400m`, `110m.hurdle`, `1500m`), un **temps faible** correspond à une **bonne** performance. Ces variables seront donc corrélées négativement à la performance globale, alors que les sauts et lancers (où une grande valeur est bonne) y seront corrélés positivement. Il faut en tenir compte pour lire les signes.

8.2.2. Mise en œuvre sous R

```
data(decathlon) res.deca <- PCA(decathlon, scale.unit = TRUE, quanti.sup =
11:12, quali.sup = 13, graph = FALSE) res.deca$eig
```

8.2.3. Analyse des valeurs propres

Composante	λ_k	τ_k (%)	$\tau_{1:k}$ (%)
1	3,272	32,72	32,72
2	1,737	17,37	50,09
3	1,405	14,05	64,14
4	1,057	10,57	74,71
5	0,685	6,85	81,56
6	0,599	5,99	87,55
7	0,451	4,51	92,06
8	0,397	3,97	96,03
9	0,215	2,15	98,18
10	0,182	1,82	100,00

La somme des valeurs propres vaut $10 = p$ (les 10 épreuves actives), ce qui confirme à nouveau l'ACP normée :

```
> sum(res.deca$eig[,1]) [1] 10
```

Choix du nombre de composantes. Contrairement à Iris, où tous les critères convergent, ils **divergent** ici, ce qui illustre concrètement la section 7 :

- **Règle de Kaiser-Guttman** : quatre valeurs propres dépassent 1 (3,27; 1,74; 1,41; 1,06), ce qui suggérerait $q = 4$;
- **Règle du coude** : la décroissance marque une première rupture nette après λ_1 , puis se stabilise; le coude se situe entre les dimensions 2 et 3;
- **Proportion cumulée** : les deux premières composantes n'expliquent que $\tau_{1:2} = 50,09\%$; il en faut cinq pour dépasser 80%.

On retient le **plan factoriel** $(\mathcal{G}_1, \mathcal{G}_2)$ pour la visualisation et l'interprétation : il concentre les deux axes les plus informatifs (50% de l'inertie), tout en gardant à l'esprit que la règle de Kaiser en conserverait quatre. La structure du décathlon est intrinsèquement plus dispersée que celle d'Iris.




FIGURE 4 – Éboulis des valeurs propres – Decathlon

8.2.4. Cercle des corrélations

```
fviz_pca_var(res.deca, col.var = "cos2", gradient.cols = c("brown",  
"orange", "blue"), repel = TRUE)
```




FIGURE 5 – Cercle des corrélations – Decathlon

Axe 1 (32,7%). Il est fortement corrélé au 100m ($-0,78$), au 110m.hurdle ($-0,75$), au 400m ($-0,68$) et au Long.jump ($+0,74$) : les épreuves de vitesse et d'explosivité forment un groupe homogène. Compte tenu du sens des variables de course (temps faible = bonne performance), cet axe représente le **niveau de performance global** : à droite les athlètes rapides et bons sauteurs, à gauche les plus faibles. La variable supplémentaire **Points** est corrélée à 0,96 avec cet axe : le premier axe reconstitue presque exactement le score officiel du décathlon.

Axe 2 (17,4%). Il est dominé par le Discus ($+0,61$) et le Shot.put ($+0,60$) : c'est l'axe de la **puissance**, qui distingue les profils de lanceurs indépendamment de la vitesse pure.

Qualité de représentation. Les variables de vitesse et de lancer sont proches du bord du cercle ($\cos^2$ élevés) ; Pole.vault et 1500m, surtout portés par l'axe 3, sont plus proches du centre dans ce plan et ne doivent pas y être sur-interprétés.

8.2.5. Plan des individus

```
fviz_pca_ind(res.deca, habillage = 13, col.ind = "cos2", palette =
c("blue", "orange"), addEllipses = TRUE, label = "none", repel = TRUE)
```




FIGURE 6 – Plan des individus coloré par compétition – Decathlon

Le plan des individus se lit principalement sur le premier axe :

- les athlètes situés tout à droite — *Karpov* ($f_{i1} = 4,62$), *Sebrle* (4,04), *Clay* (3,92) — réalisent les meilleures performances d'ensemble, avec de fortes qualités de représentation ($\cos^2$ de 0,85 ; 0,70 ; 0,71) ;
- le deuxième axe distingue les profils **puissants** (lanceurs) des profils orientés vitesse, sans séparer les athlètes en groupes nets ;
- la variable **Compétition** ne sépare pas significativement les athlètes : les ellipses se chevauchent largement. Contrairement à Iris, où la variable qualitative (l'espèce) structurait fortement le plan, il n'y a pas ici de différence marquée de profil entre les deux compétitions.

Bilan – Decathlon

En réduisant 10 épreuves à 2 composantes (50% de l'inertie), l'ACP fait apparaître une structure claire : le premier axe ordonne les athlètes selon leur **niveau global** (corrélation 0,96 avec le score officiel), le second oppose les profils de **puissance** aux autres. Cet exemple illustre un cas réaliste où les critères de choix du nombre de composantes **ne concordent pas**, obligeant à trancher selon l'objectif.

8.3. Comparaison des deux applications

	Iris	Decathlon
Individus / variables actives	150 / 4	41 / 10
Unités des variables	toutes en cm	secondes et mètres
Inertie des 2 premiers axes	95,8%	50,1%
Critères de choix de q	concordants ($q = 2$)	divergents (2 à 5)
Variable qualitative	structure le plan	ne discrimine pas

Ces deux applications illustrent deux situations types. Sur Iris, la structure est si marquée que deux composantes suffisent à presque tout résumer et que les critères convergent sans ambiguïté. Sur le décathlon, l'information est répartie sur davantage de dimensions : le premier plan ne capte que la moitié de l'inertie, les critères divergent, et le choix de q relève d'un arbitrage entre fidélité et lisibilité. C'est dans ce second cas, le plus fréquent en pratique, que les outils de la section 7 prennent tout leur sens.

Conclusion

Ce rapport a présenté le cadre mathématique complet de l'Analyse en Composantes Principales normée, depuis le prétraitement des données jusqu'à l'interprétation des résultats et l'application numérique.

Bilan mathématique : Les résultats fondamentaux établis dans ce rapport s'articulent autour de trois axes. Premièrement, la **décomposition de l'inertie** : on a montré que l'inertie totale du nuage des individus vaut $I(Z) = p = \sum_{k=1}^r \lambda_k$, reliant ainsi la dispersion des données aux valeurs propres de la matrice des corrélations R . Deuxièmement, les **propriétés des composantes principales** : les axes principaux sont les vecteurs propres de R , les composantes principales sont centrées, de variances λ_α , et deux à deux non corrélées — transformant ainsi p variables corrélées en q variables synthétiques indépendantes. Troisièmement, la **dualité individus-variables** : les deux analyses (nuage des individus dans $\mathbb{R}^p$ et nuage des variables dans $\mathbb{R}^n$) partagent les mêmes valeurs propres et sont reliées par les formules de passage $\mathbf{f}^\alpha = \sqrt{\lambda_\alpha} \mathbf{u}_\alpha$ et $\mathbf{a}^\alpha = \sqrt{\lambda_\alpha} \mathbf{v}_\alpha$. Le résultat central $a_{j\alpha} = \text{Cor}(x^j, \mathbf{f}^\alpha)$ garantit que les loadings sont directement interprétables comme des corrélations, fondant ainsi toute la lecture du cercle des corrélations.

Apport de l'application numérique : L'application au jeu de données *iris* a illustré concrètement la démarche : deux composantes principales suffisent à capturer 95,81% de l'inertie totale, et le plan factoriel révèle une structure claire entre les trois espèces d'iris, invisible dans l'espace original à 4 dimensions. Cet exemple confirme la puissance de l'ACP comme outil d'exploration visuelle des données.

Perspectives : L'ACP telle que présentée dans ce rapport est une méthode linéaire qui suppose que les structures importantes dans les données sont capturées par des directions de variance maximale. Plusieurs extensions naturelles existent. L'**ACP à noyau** (*kernel PCA*) généralise l'ACP au cadre non linéaire en projetant les données dans un espace de grande dimension via une fonction noyau, permettant de capturer des structures non linéaires. L'**Analyse Factorielle des Correspondances (AFC)** adapte le principe de l'ACP aux données qualitatives. Enfin, des méthodes plus récentes comme le ***t*-SNE** ou l'**UMAP** offrent des alternatives pour la visualisation en grande dimension, au prix d'une interprétabilité moindre. L'ACP reste néanmoins la méthode de référence pour sa simplicité, son efficacité computationnelle et la richesse de son cadre mathématique.

Références bibliographiques

1. RAKOTOMALALA, Ricco. *Analyse en Composantes Principales (ACP) : Principes et pratique*. Tutoriels Tanagra, Université Lumière Lyon 2. Disponible en ligne : <http://eric.univ-lyon2.fr/~ricco/cours/slides/ACP.pdf> [consulté en 2025–2026].
2. DUBY, C. et ROBIN, S. *Analyse en Composantes Principales*. Cours AgroParis-Tech. Disponible en ligne : https://elearn.univ-tlemcen.dz/pluginfile.php/113295/mod_resource/content/1/ACP.pdf [consulté en 2025–2026].
3. CHAVENT, Marie. *Analyse en Composantes Principales (ACP)*. Cours, Université de Bordeaux, 2013. Disponible en ligne : https://marie-chavent.perso.math.cnrs.fr/wp-content/uploads/2013/10/cours_ACP.pdf [consulté en 2025–2026].
4. FISHER, Ronald A. “The Use of Multiple Measurements in Taxonomic Problems”. *Annals of Eugenics*, vol. 7, 1936, p. 179–188. [Jeu de données iris.]
5. LÊ, Sébastien, JOSSE, Julie et HUSSON, François. “FactoMineR : An R Package for Multivariate Analysis”. *Journal of Statistical Software*, vol. 25, n° 1, 2008. Disponible en ligne : <https://www.jstatsoft.org/article/view/v025i01> [Jeu de données decathlon.]