



PROJET SEMESTRIEL

DEEP LEARNING

Réalisé par : Marie Pierre Gnilane Ndew FAYE
Formation : M1 Mathématiques appliquées aux données
Année académique : 2025/2026

Encadrant : M. Charles DE CLERCQ
Tuteur Académique : M. Pascal BOYER

Table des matières

1	Introduction	2
2	Machine Learning	4
2.1	Définition du machine learning : approche probabiliste	4
2.2	Objectif du machine learning	4
2.3	Types d'apprentissage	5
2.4	Lien avec les réseaux de neurones	5
3	Shallow Neural Networks	6
3.1	Le neurone artificiel	6
3.2	Du neurone artificiel au réseau de neurones	6
3.3	Propagation avant	7
3.4	Théorème d'approximation universelle	7
3.5	Exemple de réseau à une couche cachée	8
3.6	Limites des réseaux peu profonds	9
4	Deep Neural Networks	10
4.1	Architecture des réseaux profonds	10
4.2	Exemple d'un réseau profond à deux couches cachées	10
4.3	Rôle des couches cachées	11
4.4	Avantages des réseaux profonds	12
5	Apprentissage des réseaux neuronaux	12
5.1	Fonction de perte : approche probabiliste	12
5.2	Exemple : construction d'une fonction de perte en régression	13
5.3	Descente du gradient	14
6	Comparaison entre Shallow et Deep Neural Networks	15
6.1	Capacité de représentation	15
6.2	Complexité	15
6.3	Performances	15
6.4	Exemple de problème	16
7	Conclusion	17
8	Références	18

1 Introduction

L'essor du numérique et la croissance exponentielle des données disponibles ont profondément transformé la conception des systèmes informatiques. Alors que les approches traditionnelles reposaient principalement sur des règles définies manuellement, de nouvelles méthodes ont émergé afin de permettre aux machines d'apprendre directement à partir des données. Cette évolution a conduit au développement du machine learning, devenu aujourd'hui un domaine central de l'intelligence artificielle.

Le machine learning vise à construire des modèles capables d'extraire automatiquement des structures, des régularités ou des relations à partir de grands ensembles de données. Ces modèles sont désormais largement utilisés dans des applications telles que la reconnaissance d'images, la traduction automatique, la détection de fraudes ou les systèmes de recommandation. L'objectif n'est plus de programmer explicitement un comportement, mais de permettre à un algorithme d'améliorer ses performances à partir de l'expérience.

Dans ce rapport, nous nous concentrons plus particulièrement sur le cadre du deep learning, qui constitue aujourd'hui l'une des approches les plus performantes du machine learning.

Parmi les différentes méthodes existantes, les réseaux de neurones artificiels occupent une place majeure. Inspirés de manière abstraite du fonctionnement biologique des neurones, ces modèles sont fondés sur l'interconnexion de plusieurs unités de calcul élémentaires. Les premières architectures proposées comportaient un nombre limité de couches et sont aujourd'hui qualifiées de réseaux de neurones peu profonds (*shallow neural networks*). Bien que ces modèles possèdent une capacité théorique importante, ils présentent rapidement des limitations pratiques en termes de représentation et de passage à l'échelle.

Afin de dépasser ces limites, des architectures plus profondes ont été introduites. Les réseaux de neurones profonds (*deep neural networks*) se caractérisent par la présence de plusieurs couches cachées, permettant l'apprentissage de représentations hiérarchiques des données. Cette profondeur accrue a conduit à des avancées significatives dans des domaines tels que la vision par ordinateur ou le traitement automatique du langage naturel. Elle s'accompagne toutefois de nouveaux défis, tant sur le plan théorique que sur le plan algorithmique.

L'apprentissage des réseaux de neurones repose sur l'ajustement de leurs paramètres internes, appelés poids et biais. Cet ajustement est guidé par une fonction de perte, qui quantifie l'écart entre les prédictions du modèle et les valeurs attendues. La minimisation de cette fonction constitue le cœur du processus d'apprentissage et fait intervenir des méthodes d'optimisation itératives, telles que la descente du gradient.

Cependant, au-delà de leurs performances empiriques, les réseaux de neurones soulèvent des questions fondamentales relatives à leur capacité de représentation, à l'optimisation de leurs paramètres et à la compréhension théorique de leur comportement. Ces enjeux motivent une étude approfondie des mécanismes sous-jacents au deep learning.

Ce rapport est structuré comme suit : nous présentons tout d'abord les fondements du machine learning, avant d'introduire les réseaux de neurones peu profonds puis les architectures profondes. Nous étudions ensuite les mécanismes d'apprentissage des réseaux de neurones, en mettant l'accent sur les fonctions de perte et la descente du gradient. Enfin, une comparaison entre les réseaux peu profonds et profonds est proposée afin de mettre

en évidence leurs différences, leurs avantages et leurs limites.

2 Machine Learning

2.1 Définition du machine learning : approche probabiliste

On considère un ensemble de données supervisées

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N,$$

où $\mathbf{x}_i \in \mathbb{R}^D$ est une entrée et $y_i \in \mathbb{R}$ (régression) ou $y_i \in \{1, \dots, K\}$ (classification), la sortie associée. On a aussi $D \geq 1$ et $K \geq 2$. Dans une approche probabiliste, un modèle de machine learning paramétré par $\boldsymbol{\theta}$ définit une loi conditionnelle

$$\Pr(y \mid \mathbf{x}; \boldsymbol{\theta}),$$

qui décrit la probabilité (ou densité) d'observer y sachant $\mathbf{x}$.

En supposant les observations indépendantes et identiquement distribuées, la vraisemblance des données s'écrit

$$\Pr(\mathcal{D} \mid \boldsymbol{\theta}) = \prod_{i=1}^N \Pr(y_i \mid \mathbf{x}_i; \boldsymbol{\theta}).$$

L'apprentissage par maximum de vraisemblance consiste à déterminer

$$\boldsymbol{\theta}^* = \arg \max_{\boldsymbol{\theta}} \Pr(\mathcal{D} \mid \boldsymbol{\theta}).$$

Afin de simplifier l'optimisation, on travaille avec la log-vraisemblance :

$$\log \Pr(\mathcal{D} \mid \boldsymbol{\theta}) = \sum_{i=1}^N \log \Pr(y_i \mid \mathbf{x}_i; \boldsymbol{\theta}).$$

Maximiser la log-vraisemblance est équivalent à minimiser son opposé. On définit ainsi la fonction de perte (ou coût) comme le négatif de la log-vraisemblance :

$$\mathcal{L}(\boldsymbol{\theta}) = - \sum_{i=1}^N \log \Pr(y_i \mid \mathbf{x}_i; \boldsymbol{\theta}),$$

et le problème d'apprentissage devient

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}).$$

Ce cadre probabiliste fournit une interprétation unifiée des fonctions de perte utilisées en pratique et constitue le socle théorique de nombreux modèles, y compris les réseaux de neurones.

2.2 Objectif du machine learning

Le machine learning peut être interprété comme un problème d'approximation de fonctions. On suppose l'existence d'une relation inconnue reliant les données d'entrée $\mathbf{x}$ à une sortie y , notée

$$y = g(\mathbf{x}).$$

L'objectif est alors de construire, à partir d'un nombre fini d'observations, un modèle paramétré $f(\mathbf{x}; \boldsymbol{\theta})$ capable d'approcher cette fonction inconnue. L'apprentissage vise ainsi à réduire l'écart entre la fonction apprise et la fonction cible, tout en conservant une bonne capacité de généralisation sur de nouvelles données.

Cette formulation met en évidence le lien direct entre le machine learning et les méthodes d'optimisation, et fournit le cadre dans lequel s'inscrivent naturellement les réseaux de neurones.

2.3 Types d'apprentissage

Les méthodes de machine learning peuvent être classées selon la nature des informations disponibles lors de la phase d'apprentissage. Cette distinction permet de préciser le cadre théorique dans lequel s'inscrit l'étude des réseaux de neurones.

Apprentissage supervisé Dans l'apprentissage supervisé, le modèle dispose d'un ensemble de données étiquetées $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$. L'objectif est d'apprendre une fonction $f(\mathbf{x}; \boldsymbol{\theta})$ permettant de prédire la sortie associée à de nouvelles entrées. Ce cadre couvre aussi bien les problèmes de régression que de classification. Dans ce rapport, nous nous plaçons principalement dans ce cadre, afin de faciliter l'analyse mathématique des mécanismes d'apprentissage.

Apprentissage non supervisé Dans l'apprentissage non supervisé, seules les données d'entrée sont disponibles. Le modèle cherche alors à révéler la structure sous-jacente des données, par exemple à travers des méthodes de regroupement ou de réduction de dimension. Bien que fondamental, ce cadre ne sera pas développé dans la suite de ce travail.

Apprentissage par renforcement L'apprentissage par renforcement repose sur l'interaction entre un agent et un environnement. L'agent apprend une stratégie à partir de récompenses reçues au cours du temps. Ce cadre, adapté aux problèmes de décision séquentielle, diffère fortement du cadre supervisé et ne sera pas abordé dans ce rapport.

2.4 Lien avec les réseaux de neurones

Les réseaux de neurones artificiels s'inscrivent pleinement dans le cadre général du machine learning présenté précédemment. Ils correspondent à une famille particulière de modèles paramétrés $f(\mathbf{x}; \boldsymbol{\theta})$, dont la spécificité réside dans la structure de la fonction utilisée.

Contrairement aux modèles linéaires classiques, les réseaux de neurones reposent sur la composition de transformations linéaires et non linéaires, ce qui leur confère une forte capacité de représentation. L'apprentissage de ces modèles reste toutefois fondé sur les mêmes principes probabilistes et d'optimisation, à savoir la minimisation d'une fonction de perte issue de la log-vraisemblance.

Ainsi, le deep learning peut être vu comme une extension du cadre du machine learning, dans laquelle la complexité du modèle est principalement contrôlée par la profondeur de l'architecture.

3 Shallow Neural Networks

3.1 Le neurone artificiel

Le neurone artificiel constitue l'unité élémentaire des réseaux de neurones. Il réalise une transformation des données d'entrée à partir d'une combinaison linéaire suivie de l'application d'une fonction d'activation non linéaire.

On considère une entrée sous la forme d'un vecteur $\mathbf{x} = (x_1, \dots, x_D)^\top \in \mathbb{R}^D$. Le neurone calcule d'abord une pré-activation définie par

$$z = \sum_{j=1}^D \theta_j x_j + \theta_0,$$

où θ_j désigne les poids associés aux entrées et θ_0 un terme de biais.

La sortie du neurone est ensuite obtenue par l'application d'une fonction d'activation non linéaire :

$$h = a(z).$$

Ainsi, un neurone artificiel peut être interprété comme une fonction paramétrée non linéaire des données d'entrée.

L'introduction de la non-linéarité est essentielle : en son absence, la composition de plusieurs neurones se réduirait à une transformation linéaire unique, limitant fortement la capacité de représentation du modèle.

Par exemple, lorsque la fonction d'activation choisie est la fonction ReLU (Rectified Linear Unit), on obtient

$$h = \text{ReLU}(z), \quad \text{ReLU}(z) = \begin{cases} 0, & \text{si } z < 0, \\ z, & \text{si } z \geq 0. \end{cases}$$

Ce modèle simple constitue le point de départ de la construction des réseaux de neurones peu profonds, puis des architectures profondes.

3.2 Du neurone artificiel au réseau de neurones

Un neurone pris isolément possède une capacité de représentation très limitée. Afin de modéliser des relations plus complexes entre les données, plusieurs neurones sont interconnectés au sein d'un réseau de neurones.

Un réseau de neurones est organisé en couches successives. La couche d'entrée reçoit les données initiales. Les couches intermédiaires, appelées couches cachées, transforment progressivement les représentations internes. La couche de sortie produit la prédiction finale du modèle.

Chaque neurone d'une couche est connecté à l'ensemble des neurones de la couche suivante, ce qui permet de composer plusieurs fonctions non linéaires.

On parle de réseau de neurones peu profond (*shallow neural network*) lorsque l'architecture ne comporte qu'une seule couche cachée.

3.3 Propagation avant

Le calcul de la sortie d'un réseau de neurones peu profond repose sur un enchaînement de transformations appelé propagation avant (*forward propagation*).

Soit $\mathbf{x} \in \mathbb{R}^D$ un vecteur d'entrée et H le nombre de neurones de la couche cachée. Pour chaque neurone caché $i \in \{1, \dots, H\}$, la pré-activation est donnée par

$$z_i^{(1)} = \sum_{j=1}^D \theta_{ij}^{(1)} x_j + \theta_{i0}^{(1)}.$$

L'activation correspondante est alors

$$h_i = a(z_i^{(1)}).$$

La fonction d'activation $a(\cdot)$ est appliquée composante par composante et introduit la non-linéarité nécessaire à la capacité expressive du réseau.

Les activations de la couche cachée sont ensuite transmises à la couche de sortie. Pour chaque neurone de sortie $k \in \{1, \dots, K\}$, on obtient

$$y_k = \sum_{i=1}^H \theta_{ki}^{(2)} h_i + \theta_{k0}^{(2)}.$$

L'ensemble des paramètres du réseau est noté

$$\boldsymbol{\theta} = \{\theta^{(1)}, \theta^{(2)}\}.$$

Le réseau peut ainsi être interprété comme une fonction paramétrée

$$\mathbf{y} = f(\mathbf{x}; \boldsymbol{\theta}),$$

qui associe une sortie multivariée à une entrée multivariée.

3.4 Théorème d'approximation universelle

Le théorème d'approximation universelle fournit une justification théorique à l'utilisation des réseaux de neurones peu profonds. Il affirme que, sous certaines conditions sur la fonction d'activation, notamment sa non-linéarité, un réseau à une seule couche cachée est capable d'approximer toute fonction continue définie sur un compact de $\mathbb{R}^D$.

Plus précisément, pour toute fonction continue g et pour tout $\varepsilon > 0$, il existe un nombre fini de neurones cachés tel que

$$\|f(\mathbf{x}; \boldsymbol{\theta}) - g(\mathbf{x})\| < \varepsilon$$

pour tout $\mathbf{x}$ dans le domaine considéré.

Ce résultat met en évidence la forte capacité expressive des réseaux de neurones peu profonds et explique pourquoi une seule couche cachée peut, en théorie, suffire à représenter des fonctions très complexes.

Il s'agit toutefois d'un résultat d'existence, qui ne garantit ni la faisabilité computationnelle de l'approximation ni la facilité d'apprentissage des paramètres en pratique. En particulier, le théorème ne fournit aucune indication sur le nombre de neurones nécessaires ni sur la convergence des algorithmes d'optimisation.

3.5 Exemple de réseau à une couche cachée

On considère un réseau de neurones peu profond composé de deux entrées, d'une couche cachée contenant cinq neurones artificiels et de deux sorties.

Le vecteur d'entrée est donné par

$$\mathbf{x} = (x_1, x_2)^\top \in \mathbb{R}^2.$$

Couche cachée La couche cachée est constituée de cinq neurones notés $h_1, \dots, h_5$. Pour chaque neurone caché $i \in \{1, \dots, 5\}$, la pré-activation est définie par

$$z_i^{(1)} = \theta_{i0}^{(1)} + \theta_{i1}^{(1)} x_1 + \theta_{i2}^{(1)} x_2.$$

L'activation correspondante est alors

$$h_i = a\left(z_i^{(1)}\right), \quad i = 1, \dots, 5.$$

Chaque neurone caché réalise ainsi une transformation non linéaire paramétrée des données d'entrée.

Couche de sortie Les activations de la couche cachée sont transmises à la couche de sortie. Pour chaque neurone de sortie $j \in \{1, 2\}$, la sortie du réseau s'écrit

$$y_j = \theta_{j0}^{(2)} + \sum_{i=1}^5 \theta_{ji}^{(2)} h_i.$$

Expression globale Le réseau définit finalement une fonction paramétrée

$$\mathbf{y} = f(\mathbf{x}; \boldsymbol{\theta}),$$

où l'ensemble des paramètres est donné par

$$\boldsymbol{\theta} = \{\theta^{(1)}, \theta^{(2)}\}.$$

Cet exemple illustre la structure typique d'un réseau de neurones peu profond, dans lequel la sortie est obtenue comme une combinaison linéaire d'activations non linéaires des données d'entrée.




FIGURE 1 – Réseau de neurones peu profond à deux entrées, cinq neurones cachés et deux sorties

3.6 Limites des réseaux peu profonds

Malgré leur capacité théorique d'approximation, les réseaux de neurones peu profonds présentent plusieurs limitations importantes en pratique.

Tout d'abord, l'approximation de fonctions complexes peut nécessiter un nombre très élevé de neurones dans la couche cachée. Cette augmentation de la largeur du réseau conduit à des modèles volumineux, dont le coût en mémoire et en temps de calcul devient rapidement prohibitif.

Par ailleurs, les réseaux peu profonds effectuent l'ensemble des transformations non linéaires en une seule étape. Cette structure limite leur capacité à apprendre des représentations hiérarchiques des données, dans lesquelles des caractéristiques simples sont combinées progressivement pour former des concepts plus abstraits.

En conséquence, bien que les réseaux peu profonds soient universels au sens du théorème d'approximation, leur utilisation pratique s'avère souvent inefficace pour des tâches complexes impliquant des données de grande dimension, telles que les images ou le langage.

Ces limitations ont naturellement motivé le développement d'architectures plus profondes, capables de répartir la complexité du modèle sur plusieurs couches successives. Cette idée constitue le fondement du deep learning, étudié dans la section suivante.

4 Deep Neural Networks

4.1 Architecture des réseaux profonds

Un réseau de neurones profond se distingue d'un réseau peu profond par la présence de plusieurs couches cachées empilées entre la couche d'entrée et la couche de sortie. Cette profondeur permet au modèle de réaliser une succession de transformations non linéaires des données.

L'architecture d'un réseau profond est généralement décrite par le nombre de couches qu'il contient ainsi que par le nombre de neurones présents dans chaque couche. La profondeur contrôle le nombre de compositions successives, tandis que la largeur influence la richesse de représentation au sein d'une même couche.

Formellement, un réseau de neurones profond peut être vu comme une composition de fonctions paramétrées. Pour chaque couche $\ell \in \{1, \dots, L\}$, on définit

$$z_i^{(\ell)} = \theta_{i0}^{(\ell)} + \sum_j \theta_{ij}^{(\ell)} h_j^{(\ell-1)}, \quad h_i^{(\ell)} = a(z_i^{(\ell)}),$$

où $\mathbf{h}^{(0)} = \mathbf{x}$ représente le vecteur d'entrée et L désigne le nombre de couches cachées. Cette écriture met en évidence que les réseaux profonds correspondent à des fonctions fortement non linéaires, dont la complexité provient principalement de la profondeur de la composition.

Chaque couche transforme la représentation issue de la couche précédente, produisant ainsi des représentations intermédiaires de plus en plus abstraites. La sortie finale du réseau est obtenue à partir de la dernière couche, éventuellement suivie d'une fonction d'activation adaptée au problème considéré.

L'architecture d'un réseau profond constitue un choix central, car elle influence directement la capacité de représentation du modèle, son coût computationnel ainsi que sa capacité de généralisation.

4.2 Exemple d'un réseau profond à deux couches cachées

On considère un réseau de neurones profond recevant une entrée scalaire $x \in \mathbb{R}$ et produisant une sortie scalaire $y \in \mathbb{R}$. Le réseau comporte deux couches cachées, chacune composée de trois neurones artificiels.

Première couche cachée. La première couche transforme l'entrée x en trois activations intermédiaires. Pour $i \in \{1, 2, 3\}$, on définit

$$z_i^{(1)} = \theta_{i0}^{(1)} + \theta_{i1}^{(1)} x, \quad h_i^{(1)} = a(z_i^{(1)}).$$

Deuxième couche cachée. Les activations de la première couche sont ensuite combinées par une seconde couche cachée composée de trois neurones. Pour $j \in \{1, 2, 3\}$, on définit

$$z_j^{(2)} = \theta_{j0}^{(2)} + \theta_{j1}^{(2)} h_1^{(1)} + \theta_{j2}^{(2)} h_2^{(1)} + \theta_{j3}^{(2)} h_3^{(1)}, \quad h_j^{(2)} = a(z_j^{(2)}).$$

Couche de sortie. La sortie finale du réseau est obtenue par une combinaison linéaire des activations de la seconde couche cachée :

$$y = \theta_0^{(3)} + \theta_1^{(3)}h_1^{(2)} + \theta_2^{(3)}h_2^{(2)} + \theta_3^{(3)}h_3^{(2)}.$$

Ce réseau illustre le principe fondamental du deep learning : la composition successive de transformations non linéaires permettant de construire des fonctions complexes à partir d'opérations élémentaires.




FIGURE 2 – Réseau de neurones profond à deux couches cachées (architecture 1–3–3–1)

4.3 Rôle des couches cachées

Les couches cachées jouent un rôle central dans le fonctionnement des réseaux de neurones profonds. Elles permettent au modèle de transformer progressivement les données d'entrée en représentations internes mieux adaptées à la tâche considérée.

Chaque couche applique une transformation non linéaire à la représentation produite par la couche précédente. Les activations obtenues peuvent être interprétées comme des variables latentes, apprises automatiquement à partir des données, et non comme des caractéristiques définies manuellement.

La succession de couches cachées induit ainsi une organisation hiérarchique des représentations. Les premières couches apprennent généralement des structures simples, tandis que les couches plus profondes combinent ces informations afin de modéliser des concepts plus abstraits.

D'un point de vue fonctionnel, la profondeur permet de factoriser une fonction complexe en une composition de fonctions plus simples. Cette décomposition facilite l'approximation de relations non linéaires complexes et constitue l'un des principaux avantages des architectures profondes.

Enfin, bien que les représentations internes apprises par les couches cachées soient difficiles à interpréter individuellement, leur organisation globale permet au réseau d'extraire efficacement des informations pertinentes à partir des données brutes.

4.4 Avantages des réseaux profonds

Les réseaux de neurones profonds présentent plusieurs avantages majeurs par rapport aux architectures peu profondes, en particulier pour des problèmes impliquant des données de grande dimension.

Tout d'abord, la profondeur permet une représentation plus efficace de certaines fonctions complexes. Des résultats théoriques ont montré que des fonctions pouvant nécessiter un nombre exponentiel de neurones dans un réseau peu profond peuvent être représentées avec un nombre bien plus réduit de paramètres dans une architecture profonde.

Par ailleurs, les réseaux profonds sont capables d'apprendre automatiquement des représentations intermédiaires pertinentes à partir des données brutes. Cette propriété réduit fortement la dépendance au *feature engineering* manuel, qui constituait une étape essentielle dans les méthodes de machine learning plus classiques.

La structure hiérarchique des réseaux profonds favorise également une meilleure généralisation lorsque le modèle est entraîné sur des jeux de données suffisamment riches. En combinant progressivement des représentations simples pour former des concepts plus abstraits, le réseau parvient à capturer efficacement la structure sous-jacente des données.

Ces propriétés expliquent le succès des réseaux profonds dans de nombreux domaines applicatifs, notamment la vision par ordinateur, le traitement automatique du langage naturel et la reconnaissance vocale.

Si la structure des réseaux de neurones profonds explique leur forte capacité de représentation, leur efficacité repose également sur les mécanismes d'apprentissage permettant d'ajuster leurs paramètres à partir des données. Nous présentons dans la section suivante les principes fondamentaux de l'apprentissage des réseaux de neurones.

5 Apprentissage des réseaux neuronaux

5.1 Fonction de perte : approche probabiliste

Dans de nombreux problèmes d'apprentissage, la sortie d'un réseau de neurones peut être interprétée comme définissant une distribution de probabilité conditionnelle $\Pr(y \mid x; \boldsymbol{\theta})$, où $\boldsymbol{\theta}$ désigne l'ensemble des paramètres du modèle.

On considère un ensemble de données d'apprentissage

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N,$$

supposées indépendantes et identiquement distribuées. La vraisemblance du modèle correspond alors à la probabilité d'observer l'ensemble des données sous le modèle paramétré par $\boldsymbol{\theta}$, et s'écrit

$$\Pr(\mathcal{D} \mid \boldsymbol{\theta}) = \prod_{i=1}^N \Pr(y_i \mid x_i; \boldsymbol{\theta}).$$

L'apprentissage par maximum de vraisemblance consiste à déterminer les paramètres rendant les observations les plus probables :

$$\boldsymbol{\theta}^* = \arg \max_{\boldsymbol{\theta}} \Pr(\mathcal{D} \mid \boldsymbol{\theta}).$$

Afin de simplifier l'optimisation, on travaille avec le logarithme de la vraisemblance, ce qui permet de transformer le produit en une somme :

$$\log \Pr(\mathcal{D} \mid \boldsymbol{\theta}) = \sum_{i=1}^N \log \Pr(y_i \mid x_i; \boldsymbol{\theta}).$$

Maximiser la log-vraisemblance étant équivalent à minimiser son opposé, on introduit la fonction de perte définie par

$$\mathcal{L}(\boldsymbol{\theta}) = - \sum_{i=1}^N \log \Pr(y_i \mid x_i; \boldsymbol{\theta}).$$

Le problème d'apprentissage peut alors être formulé sous la forme

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}).$$

Cette formulation met en évidence le lien direct entre apprentissage des réseaux de neurones, modélisation probabiliste et optimisation mathématique. Elle constitue le cadre général dans lequel sont construites la plupart des fonctions de perte utilisées en pratique.

5.2 Exemple : construction d'une fonction de perte en régression

La formulation précédente étant générale, nous considérons à présent un cas particulier afin d'en illustrer concrètement les implications. On se place dans le cadre d'un problème de régression, tel que présenté par Prince.

On suppose disposer d'un ensemble de données supervisées

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N,$$

où $x_i \in \mathbb{R}$ représente une entrée scalaire et $y_i \in \mathbb{R}$ la sortie associée.

Le modèle est défini par une fonction paramétrée

$$y = f(x; \boldsymbol{\theta}),$$

qui fournit une prédiction pour chaque entrée.

Modélisation probabiliste

On suppose que les observations sont bruitées, et que la sortie réelle peut s'écrire sous la forme

$$y_i = f(x_i; \boldsymbol{\theta}) + \varepsilon_i,$$

où le bruit ε_i est modélisé par une variable aléatoire gaussienne centrée de variance σ^2 :

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

Le paramètre σ^2 contrôle le niveau de bruit supposé présent dans les observations et influence l'importance accordée aux écarts entre prédictions et valeurs réelles.

Cette hypothèse implique que la distribution conditionnelle de l'observation y_i sachant x_i est donnée par

$$\Pr(y_i \mid x_i; \boldsymbol{\theta}) = \mathcal{N}(y_i \mid f(x_i; \boldsymbol{\theta}), \sigma^2).$$

Log-vraisemblance

En supposant les données indépendantes et identiquement distribuées, la log-vraisemblance s'écrit

$$\log \Pr(\mathcal{D} \mid \boldsymbol{\theta}) = \sum_{i=1}^N \log \Pr(y_i \mid x_i; \boldsymbol{\theta}).$$

En développant l'expression de la loi gaussienne, on obtient

$$\log \Pr(\mathcal{D} \mid \boldsymbol{\theta}) = -\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - f(x_i; \boldsymbol{\theta}))^2 + C,$$

où C désigne un terme constant indépendant de $\boldsymbol{\theta}$.

Fonction de perte associée

Le terme constant pouvant être ignoré lors de l'optimisation, maximiser la log-vraisemblance revient à minimiser la fonction

$$\mathcal{L}(\boldsymbol{\theta}) = \sum_{i=1}^N (y_i - f(x_i; \boldsymbol{\theta}))^2.$$

Cette expression correspond à la perte quadratique usuelle. Elle apparaît ainsi comme la conséquence directe de l'hypothèse de bruit gaussien sur les données, et non comme un choix arbitraire.

Cet exemple illustre le lien fondamental entre hypothèses probabilistes, fonction de perte et apprentissage des paramètres du modèle.

5.3 Descente du gradient

Une fois la fonction de perte définie, l'apprentissage d'un réseau de neurones consiste à résoudre le problème d'optimisation

$$\boldsymbol{\theta}^* = \arg \min_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}).$$

Dans le cas des réseaux de neurones, la fonction de perte est généralement non convexe et ne peut être minimisée analytiquement. Il est donc nécessaire de recourir à des méthodes d'optimisation numérique.

La descente du gradient est l'une des méthodes les plus utilisées. Elle repose sur une mise à jour itérative des paramètres selon la règle

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta \nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}^{(t)}),$$

où $\eta > 0$ désigne le taux d'apprentissage.

Le gradient $\nabla_{\boldsymbol{\theta}} \mathcal{L}$ indique la direction de plus forte augmentation de la fonction de perte. En se déplaçant dans la direction opposée, l'algorithme cherche à réduire progressivement la valeur de la perte à chaque itération.

Dans les réseaux de neurones, le calcul efficace de ces gradients est rendu possible grâce à l'algorithme de rétropropagation du gradient (*backpropagation*), qui exploite la structure en couches du modèle et la règle de la chaîne.

Ainsi, l'apprentissage d'un réseau de neurones peut être interprété comme un processus itératif au cours duquel les paramètres sont ajustés progressivement afin d'améliorer les prédictions du modèle sur les données d'entraînement.

La qualité de l'apprentissage dépend alors fortement du choix du taux d'apprentissage, de l'initialisation des paramètres et de la forme de la fonction de perte.

6 Comparaison entre Shallow et Deep Neural Networks

6.1 Capacité de représentation

Les réseaux de neurones peu profonds et profonds possèdent tous deux une capacité théorique d'approximation élevée. En particulier, le théorème d'approximation universelle garantit qu'un réseau à une seule couche cachée peut approximer toute fonction continue sous certaines conditions.

Cependant, cette capacité théorique ne reflète pas nécessairement l'efficacité de la représentation. Les réseaux peu profonds peuvent nécessiter un nombre très important de neurones pour représenter des fonctions complexes, tandis que les réseaux profonds exploitent la composition de plusieurs couches pour construire des représentations hiérarchiques plus compactes.

Ainsi, la profondeur permet souvent de représenter certaines fonctions avec un nombre de paramètres significativement plus faible que dans le cas des réseaux peu profonds.

6.2 Complexité

Les réseaux peu profonds présentent une structure simple, ce qui facilite leur analyse théorique et leur mise en œuvre. Leur nombre limité de couches réduit les difficultés liées à l'optimisation et permet un entraînement relativement stable.

À l'inverse, les réseaux profonds introduisent une complexité accrue, tant du point de vue du nombre de paramètres que des méthodes d'apprentissage. L'entraînement de ces modèles peut nécessiter des techniques spécifiques telles que l'initialisation adaptée des poids, la normalisation ou l'utilisation d'architectures particulières.

La profondeur apporte ainsi une plus grande puissance de modélisation, au prix d'une complexité computationnelle et algorithmique plus élevée.

6.3 Performances

En pratique, les performances des réseaux de neurones dépendent fortement de la nature des données et de la tâche considérée. Pour des problèmes simples ou faiblement structurés, les réseaux peu profonds peuvent obtenir des résultats satisfaisants tout en restant rapides à entraîner et faciles à interpréter.

En revanche, pour des données complexes et de grande dimension, telles que les images, les signaux audio ou le texte, les réseaux profonds surpassent généralement les modèles peu profonds. Leur capacité à apprendre automatiquement des représentations hiérarchiques explique leur succès dans de nombreux domaines de l'intelligence artificielle.

Le choix entre réseaux peu profonds et profonds dépend ainsi d'un compromis entre complexité du modèle, coût de calcul et niveau de performance attendu.

6.4 Exemple de problème

Problème. On considère deux réseaux qui prennent une entrée scalaire x et produisent une sortie scalaire y . Le premier est peu profond (shallow) avec une couche cachée de $D = 95$ neurones. Le second est profond (deep) avec $K = 10$ couches, chacune contenant $D = 5$ neurones. On suppose des couches entièrement connectées avec biais et une activation ReLU.

Nombre de paramètres. Pour le réseau shallow :

$$P_{\text{shallow}} = (95 \times 1 + 95) + (1 \times 95 + 1) = 95 + 95 + 95 + 1 = 286.$$

Pour le réseau deep :

$$P_{\text{deep}} = (5 \times 1 + 5) + 9(5 \times 5 + 5) + (1 \times 5 + 1) = 10 + 270 + 6 = 286.$$

Les deux réseaux ont donc 286 paramètres.

Régions linéaires (entrée 1D). Un réseau shallow avec D neurones ReLU définit au plus $D + 1$ régions linéaires :

$$R_{\text{shallow}} \leq 95 + 1 = 96.$$

Pour un réseau deep de largeur D et profondeur K , on peut majorer :

$$R_{\text{deep}} \leq (D + 1)^K = 6^{10} = 60\,466\,176.$$

Cette borne constitue une majoration théorique et ne correspond pas nécessairement au nombre effectif de régions linéaires atteintes en pratique.

Vitesse d'exécution. En nombre de produits, le shallow requiert environ $95 + 95 = 190$ multiplications, tandis que le deep requiert environ $5 + 9 \cdot 25 + 5 = 235$ multiplications. Le réseau shallow devrait donc s'exécuter plus rapidement (et avec moins de latence, car il est moins profond).




FIGURE 3 – Réseau peu profond avec une seule couche cachée large ($D = 95$)




FIGURE 4 – Réseau profond : $K = 10$ couches, chacune de largeur $D = 5$ (schéma, couches intermédiaires omises)

Cet exemple met en évidence que, à nombre de paramètres équivalent, la profondeur du réseau peut conduire à une capacité de représentation nettement supérieure, au prix toutefois d'une complexité algorithmique et d'une difficulté d'optimisation accrues.

Ce compromis entre expressivité, coût computationnel et stabilité de l'apprentissage constitue l'un des enjeux centraux du deep learning moderne.

7 Conclusion

Dans ce projet, nous avons étudié les réseaux de neurones artificiels dans le cadre de l'apprentissage automatique, en mettant en évidence la transition entre les réseaux peu profonds et les architectures profondes.

Après un rappel des principes fondamentaux du machine learning paramétrique, les réseaux de neurones peu profonds ont été introduits, ainsi que leur fonctionnement et leur capacité théorique d'approximation. Bien que ces modèles possèdent une expressivité importante, leurs limites pratiques, notamment en termes de représentation et de passage à l'échelle, ont motivé l'introduction de réseaux plus profonds.

Les réseaux de neurones profonds se distinguent par leur organisation en couches successives, permettant l'apprentissage automatique de représentations hiérarchiques des données. Cette propriété constitue un avantage majeur pour le traitement de données complexes, telles que les images, le son ou le texte.

Les mécanismes d'apprentissage ont ensuite été étudiés à travers une approche probabiliste des fonctions de perte et l'utilisation de la descente du gradient comme méthode centrale

d’optimisation. La comparaison entre réseaux peu profonds et profonds a permis de mettre en évidence les compromis fondamentaux entre capacité de représentation, complexité algorithmique et performances.

Ces résultats soulignent le rôle central du deep learning dans les méthodes modernes d’intelligence artificielle, tout en rappelant l’importance d’un cadre théorique rigoureux pour analyser le comportement, les limites et les enjeux associés à ces modèles.

8 Références

- S. J. D. Prince, *Understanding Deep Learning*, MIT Press, 2023.
- Cours et supports vidéo sur le deep learning, Guillaume SAINT CIRGUE.
- Wikipédia, pages relatives au machine learning et aux réseaux de neurones.