

Analyse en Composantes Principales (ACP)

Projet semestriel 2

Mlle FAYE Marie Pierre Gnilane Ndew

Année universitaire 2025–2026

Université Sorbonne Paris Nord

Institut Galilée

Master 1 – Mathématiques appliquées aux données

Plan de la présentation

Introduction

Cadre mathématique

Nuage des individus

Nuage des variables

Dualité et SVD

Interprétation

Applications numériques

Conclusion

Introduction

Pourquoi l'ACP ?

Le problème

Quand p est grand, les données sont **corrélées** (redondance) et **impossibles à visualiser**.

La solution : l'ACP

L'ACP **réduit la dimension** en transformant p variables corrélées en quelques **composantes principales non corrélées**, tout en conservant le **maximum d'information**.

p variables corrélées $\longrightarrow q \ll p$ composantes non corrélées

Exemple – Iris : 4 variables corrélées (ex. longueur et largeur du pétale) $\rightarrow$ 2 composantes.

Cadre mathématique

Matrice des données

$$X = (x_{ij})_{n \times p}$$

n individus, p variables

Double lecture :

- **Par lignes** : n individus dans $\mathbb{R}^p$
→ nuage des individus
- **Par colonnes** : p variables dans $\mathbb{R}^n$
→ nuage des variables

Exemple – Iris : 150 fleurs dans $\mathbb{R}^4$ (nuage des individus); 4 variables dans $\mathbb{R}^{150}$ (nuage des variables).

La dualité

Les deux nuages partagent les **mêmes valeurs propres** λ_α : c'est le cœur de l'ACP.

Centrer

$$y_{ij} = x_{ij} - \bar{x}_j$$

→ le barycentre du nuage va à l'**origine**

→ ne modifie pas les distances

Réduire

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

→ chaque variable a une **variance = 1**

→ aucune variable n'écrase les autres

Résultat

La matrice Z a des colonnes de **moyenne nulle** et de **variance 1** → ACP normée, sur la matrice de corrélation $R = \frac{1}{n} Z^T Z$.

Exemple – Iris : malgré des variables toutes en cm, on les réduit pour une ACP normée.

Définition

L'inertie mesure la **dispersion globale** du nuage autour du barycentre $G = 0$:

$$I(Z) = \frac{1}{n} \sum_{i=1}^n \|z_i\|^2$$

Résultat fondamental

$$I(Z) = \sum_{j=1}^p \text{Var}(z^j) = p = \sum_{k=1}^r \lambda_k$$

L'inertie totale vaut p et se **décompose** sur les valeurs propres de R .

Preuve : interversion des sommations + $\text{tr}(R) = p$ (diagonale de 1).

Nuage des individus

Projection sur un axe

La coordonnée de l'individu i sur l'axe Δ_α (vecteur directeur $\mathbf{v}_\alpha$, $\|\mathbf{v}_\alpha\| = 1$) :

$$f_{i\alpha} = \mathbf{z}_i^\top \mathbf{v}_\alpha$$

Mauvaise direction

Les individus se confondent au même point

→ information **perdue**

Bonne direction

Les individus restent **écartés**

→ information **conservée**

Objectif : trouver la direction qui maximise la **variance des projections**.

Exemple – Iris : sur une mauvaise direction, les 3 espèces se mélangeraient ; la bonne direction

Premier axe principal Δ_1

$$v_1 = \arg \max_{\|v\|=1} \text{Var}(Zv) = \arg \max_{\|v\|=1} v^\top R v$$

Axe $\alpha \geq 2$

On maximise la même quantité sous la contrainte $v_\alpha \perp v_1, \dots, v_{\alpha-1}$

→ chaque nouvel axe apporte une **information nouvelle**.

Résolution par Lagrange

Le Lagrangien $\mathcal{L} = v^\top R v - \lambda(\|v\|^2 - 1)$ donne :

$$Rv = \lambda v$$

→ v_α est **vecteur propre** de R , et la variance vaut λ_α .

Théorème spectral

R symétrique réelle $\Rightarrow$ diagonalisable dans une base orthonormée :

$$R = V\Lambda V^\top, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_1 \geq \dots \geq \lambda_p \geq 0$$

Ce qu'on obtient

- les **vecteurs propres** v_α = les **directions** des axes principaux ;
- les **valeurs propres** λ_α = la **variance captée** par chaque axe ;
- $\sum_\alpha \lambda_\alpha = p$ = l'inertie totale.

Exemple – Iris : R est 4×4 , et sa diagonalisation donne les 4 couples $(\lambda_\alpha, v_\alpha)$.

Énoncé

v_α est le **vecteur propre** de R associé à λ_α :

$$Rv_\alpha = \lambda_\alpha v_\alpha$$

Conséquence

Les vecteurs $v_1, \dots, v_p$ forment une **base orthonormée** de $\mathbb{R}^p$ (théorème spectral).

L'indice $\alpha \in \{1, \dots, p\}$ numérote les axes : p = nombre de **variables**, pas d'individus.

C'est cette relation $Rv_\alpha = \lambda_\alpha v_\alpha$ que l'on réutilise dans toutes les preuves suivantes.

Exemple – Iris : $p = 4$ donc $\alpha \in \{1, 2, 3, 4\}$ – pas 150, le nombre de fleurs.

Propriété 2 – Variance de la composante principale

Distinction fondamentale

- **Axe principal** Δ_α = la **direction** $v_\alpha \in \mathbb{R}^p$ (la « règle graduée ») ;
- **Composante principale** $f^\alpha = Zv_\alpha \in \mathbb{R}^n$ = les n **valeurs projetées** (les mesures).

Énoncé

f^α est **centrée** et sa variance vaut :

$$\text{Var}(f^\alpha) = v_\alpha^\top R v_\alpha = \lambda_\alpha$$

La variance captée par l'axe α est exactement λ_α : c'est pourquoi les valeurs propres mesurent l'information.

Exemple – Iris : v_1 a 4 coordonnées (la direction) ; f^1 en a 150 (une par fleur), de variance $\lambda_1 = 2\,918$

Propriété 3 – Composantes non corrélées

Énoncé

Pour tout $\alpha \neq \beta$:

$$\text{Cov}(f^\alpha, f^\beta) = \mathbf{v}_\alpha^\top R \mathbf{v}_\beta = \lambda_\beta (\mathbf{v}_\alpha^\top \mathbf{v}_\beta) = 0$$

Ce que ça signifie

On est passé de p variables **corrélées** (enchevêtrées) à q composantes **non corrélées** (indépendantes), ordonnées par information décroissante :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_q$$

*Diagonaliser R = **décorrélér**.*

Exemple – Iris : la position d'une fleur sur l'axe 1 ne dit rien sur sa position sur l'axe 2

Définition

La matrice F regroupe les coordonnées de tous les individus sur tous les axes :

$$F = ZV \in \mathcal{M}_{n \times q}(\mathbb{R})$$

- **Colonne** α = composante principale f^α : les n coordonnées sur l'axe α ;
- **Ligne** i = nouvelles coordonnées de l'individu i dans le repère factoriel ;
- $f_{i\alpha}$ = ce qu'on représente sur le **plan factoriel**.

Résumé

F : centré, variances $\lambda_1 \geq \dots \geq \lambda_q$, colonnes non corrélées.

Exemple – Iris : F est 150×2 si $q = 2$ – une ligne par fleur.

Nuage des variables

Position des variables

Les variables centrées-réduites z^j ont $\|z^j\|_N = 1$: elles sont sur la **sphère unité** de $(\mathbb{R}^n, N)$.

Corrélation = cosinus

$$\text{Cor}(z^j, z^m) = \cos \theta_N(z^j, z^m)$$

- Angle aigu (< 90) $\rightarrow$ corrélées positivement ;
- Angle droit ($= 90$) $\rightarrow$ non corrélées ;
- Angle obtus (> 90) $\rightarrow$ corrélées négativement.

Problème d'optimisation côté variables

Premier axe $\mathcal{G}_1$

On maximise la **somme des** $\cos^2$ des angles entre les variables et l'axe :

$$u_1 = \arg \max_{\|u\|_N=1} \sum_{j=1}^p \cos^2 \theta_N(z^j, u) = \arg \max_{\|u\|_N=1} \left\| Z^\top N u \right\|^2$$

Individus (sec. 3)

Maximiser la **variance**
dans $(\mathbb{R}^p, I_p)$

Variables (sec. 4)

Maximiser la **somme des** $\cos^2$
dans $(\mathbb{R}^n, N)$

Deux objectifs différents $\rightarrow$ **mêmes** λ_α !

Résolution par Lagrange

u_α est vecteur propre de $\frac{1}{n}ZZ^\top$ pour la valeur propre λ_α :

$$\frac{1}{n}ZZ^\top u_\alpha = \lambda_\alpha u_\alpha$$

Lien avec $R = \frac{1}{n}Z^\top Z$

Si $Rv = \lambda v$, alors $u = Zv$ vérifie :

$$\frac{1}{n}ZZ^\top u = \lambda u$$

→ **mêmes valeurs propres** λ_α , mais $v_\alpha \in \mathbb{R}^p$ et $u_\alpha \in \mathbb{R}^n$.

Exemple – Iris : R est 4×4 , $\frac{1}{n}ZZ^\top$ serait 150×150 – mêmes 4 valeurs propres non nulles.

Double lecture de λ_α

$$\lambda_\alpha = \underbrace{\text{Var}(f^\alpha)}_{\text{variance côté individus}} = \underbrace{\sum_{j=1}^p \cos^2 \theta_N(z^j, u_\alpha)}_{\text{somme des } \cos^2 \text{ côté variables}} = \sum_{j=1}^p a_{j\alpha}^2$$

Deux sommes à ne pas confondre

$$\underbrace{\sum_{j=1}^p a_{j\alpha}^2}_{\text{axe fixé}} = \lambda_\alpha \quad \text{contre} \quad \underbrace{\sum_{\alpha=1}^r a_{j\alpha}^2}_{\text{variable fixée}} = 1$$

Rayon du cercle des corrélations = 1, et non $\sqrt{\lambda_\alpha}$.

Exemple – Iris : $\lambda_1 = 2,918$ = somme sur les 4 variables (axe 1); pour *Petal.Length* seule, $l_{17/33}$

Dualité et SVD

Les deux formules clés

$$f^\alpha = Z v_\alpha = \sqrt{\lambda_\alpha} u_\alpha \quad \text{et} \quad a^\alpha = Z^\top N u_\alpha = \sqrt{\lambda_\alpha} v_\alpha$$

En matriciel : $F = U \Lambda^{1/2}$ et $A = V \Lambda^{1/2}$.

Ce que ça veut dire en pratique

- Connaître v_α suffit à calculer u_α et f^α ;
- Connaître u_α suffit à calculer v_α et a^α ;
- On ne résout qu'un **seul** problème aux valeurs propres.

Exemple – Iris : les 4 vecteurs v_α suffisent à retrouver les 150 fleurs.

Résultat fondamental

$$a_{j\alpha} = \text{Cor}(x^j, f^\alpha) \in [-1, 1]$$

Les loadings sont directement les **corrélations** entre chaque variable et chaque composante principale.

Conséquence : le cercle des corrélations

Chaque variable j est représentée par le point (a_{j1}, a_{j2}) dans le plan factoriel :

- **Proche du bord** (longueur ≈ 1) $\rightarrow$ bien représentée ;
- **Proche du centre** $\rightarrow$ mal représentée, à ne pas interpréter.

Exemple – Iris : Petal.Length sur l'axe 1 = sa corrélation avec cet axe (0,96).

Décomposition en Valeurs Singulières (SVD)

Définition

Toute matrice Z de rang r admet une décomposition de la forme :

$$Z = U\Delta V^{\top}$$

avec U ($n \times r$) et V ($p \times r$) à colonnes orthonormées, $\Delta = \text{diag}(\delta_1, \dots, \delta_r)$.

Lien avec les valeurs propres

$$\lambda_k = \frac{\delta_k^2}{n}$$

En pratique, on utilise la SVD de Z directement (plus stable numériquement que diagonaliser R).

Exemple – Iris : c'est cette SVD que $\text{PCA}(\text{iris}, \dots)$ utilise en arrière-plan.

Interprétation

Cos² – qualité de représentation

Individu i sur axe α :

$$\cos^2 \theta_{i\alpha} = \frac{f_{i\alpha}^2}{\|z_i\|^2}$$

Variable j sur axe α :

$$\cos^2 \theta_{j\alpha} = a_{j\alpha}^2$$

Proche de 1 → **bien représenté**.

Contribution – influence

Individu i :

$$\text{Ctr}(i, \alpha) = \frac{f_{i\alpha}^2}{n\lambda_\alpha}$$

Variable j :

$$\text{Ctr}(j, \alpha) = \frac{a_{j\alpha}^2}{\lambda_\alpha}$$

$\sum = 1$ dans les deux cas.

Exemple – Iris : une virginica excentrée et bien représentée sur l'axe 1 aura une forte contribution.

Proportion d'inertie expliquée

$$\tau_\alpha = \frac{\lambda_\alpha}{p} \in [0, 1], \quad \tau_{1:q} = \frac{\lambda_1 + \dots + \lambda_q}{p}$$

- **Règle du coude** : point d'inflexion de l'éboulis ;
- **Kaiser-Guttman** : $\lambda_k > 1$;
- **Karlis-Saporta-Spinaki** :
 $\lambda_k > 1 + 2\sqrt{\frac{p-1}{n-1}}$.
- **Bâtons brisés** : $\lambda_k > \sum_{m=k}^p \frac{1}{m}$;
- **Analyse parallèle** : comparaison aux données aléatoires (la plus rigoureuse).

En pratique

Les critères ne concordent pas toujours → **jugement** selon l'objectif.

Applications numériques

Application 1 – Iris : valeurs propres

Le jeu de données

$n = 150$ fleurs, $p = 4$ variables (en cm)

3 espèces : *setosa*, *versicolor*, *virginica*


Species $\rightarrow$ variable **supplémentaire**

Vérification


$\sum \lambda_k = 4 = p \checkmark \rightarrow$ ACP normée
confirmée

Axe	λ_k	τ_k	$\tau_{1:k}$
1	2,918	73,0%	73,0%
2	0,914	22,9%	95,8%
3	0,147	3,7%	99,5%
4	0,021	0,5%	100%

Tous les critères convergent vers $q = 2$.



Application 1 – Iris : cercle des corrélations



Axe 1 (73%) – Taille de la fleur

Petal.Length, Petal.Width,

Sepal.Length → droite


Angles aigus → fortement corrélées

Axe 2 (22,9%) – Largeur du sépale

Sepal.Width seule → haut

⊥ à Sepal.Length → non corrélées

Application 1 – Iris : plan des individus



Lecture

Séparation sur l'axe 1 (taille) :

- *Setosa* → gauche (petits pétales) ;
- *Versicolor* → centre ;
- *Virginica* → droite (grands pétales).

Remarque

Versicolor et *virginica* se chevauchent légèrement → proximité biologique.
L'axe 2 ne discrimine pas les espèces.

Application 2 – Decathlon : valeurs propres

Le jeu de données

$n = 41$ athlètes, $p = 10$ épreuves

Unités : secondes (courses) et mètres (sauts/lancers)

Points, Rank $\rightarrow$ quanti. sup.


Competition $\rightarrow$ quali. sup.

ACP normée indispensable


Les unités sont réellement différentes $\rightarrow$ sans normalisation, les variables à forte variance domineraient.

Axe	λ_k	τ_k	$\tau_{1:k}$
1	3,272	32,7%	32,7%
2	1,737	17,4%	50,1%
3	1,405	14,1%	64,1%
4	1,057	10,6%	74,7%
5	0,685	6,9%	81,6%
...	...	...	...

Kaiser $\rightarrow q = 4$; *plan factoriel* $\rightarrow q = 2$.



Application 2 – Decathlon : cercle des corrélations



Axe 1 (32,7%) – Niveau global

100m, 110m.hurdle (–), Long.jump (+)

Corrélé à 0,96 avec Points


→ reconstitue le **score officiel**

Axe 2 (17,4%) – Puissance

Discus, Shot.put (+)

→ profil **lanceur**, indépendant de la vitesse

Application 2 – Decathlon : plan des individus



Lecture

- *Karpov, Sebrle, Clay* → droite (meilleurs niveaux) ;
- Axe 2 : profils puissants vs vitesse ;
- Competition : ellipses chevauchées → pas de différence entre Décastar et JO.

Différence avec Iris

La variable quali. ne structure pas le plan → la compétition n'explique pas les profils.

Comparaison des deux applications

	Iris	Decathlon
n / p actifs	150 / 4	41 / 10
Unités	toutes en cm	s et m
$\tau_{1:2}$	95,8%	50,1%
Critères de q	concordants ($q = 2$)	divergents (2 à 4)
Variable quali.	structure le plan	ne discrimine pas

Deux cas types

Iris = cas idéal : structure forte, critères concordants.

Decathlon = cas réaliste : information dispersée, critères qui divergent, choix de q par jugement.

Conclusion

Bilan mathématique

- $I(Z) = p = \sum \lambda_k$: l'inertie se décompose sur les valeurs propres ;
- Trois propriétés fondamentales : vecteurs propres, variance = λ_α , décorrélation ;
- Dualité : deux nuages, un seul spectre λ_α , reliés par les formules de passage.

Perspectives

- **ACP à noyau** : cas non linéaire ;
- **AFC** : données qualitatives ;
- **t -SNE / UMAP** : visualisation en grande dimension.

1. RAKOTOMALALA, R. *ACP : Principes et pratique*. Tutoriels Tanagra, Université Lyon 2.
2. DUBY, C. et ROBIN, S. *Analyse en Composantes Principales*. Cours AgroParisTech.
3. CHAVENT, M. *Analyse en Composantes Principales*. Université de Bordeaux, 2013.
4. FISHER, R.A. "The Use of Multiple Measurements in Taxonomic Problems". *Annals of Eugenics*, 1936.
5. LÊ, S., JOSSE, J. et HUSSON, F. "FactoMineR : An R Package for Multivariate Analysis". *Journal of Statistical Software*, 2008.